AI · LLM 데이터 포트폴리오

김태형

TaeHyeong Kim

모델이 배우는 문장과 검색할 문서를 직접 설계했습니다

경북대학교 컴퓨터학부 · 2027.02 졸업 예정 · xogud3624@gmail.com · github.com/KTHYEONG

모델 앞단의 데이터를 맡았습니다. Emori(팀)는 상담 문장 모델의 학습 데이터, Witches(팀)는 학사 규정 검색용 문서 구조화, Port Entity Matching(개인)은 한글 선박명 매칭입니다. 팀 프로젝트는 제 담당과 팀 전체 결과를 나눠 적었습니다.

핵심 역량

문서 전처리와 구조화

HWP·DOCX·PDF를 Markdown 하나로 통일하고, 조·항·호 계층을 표시해 청킹이 조항 경계를 알게 했습니다.

학습 데이터 설계

증강 규칙과 정답 문장의 문체를 직접 정하고, 부자연스러운 문체는 학습에서 뺐습니다.

평가와 한계의 정직한 표기

팀 전체 지표에는 팀 라벨을 붙이고, 평가 데이터가 작아 흔들리는 점수는 통계 기준으로 판단했습니다.

대표 결과

Emori

50세트

증강 학습 데이터

규칙 기반, 감정·강도 값은 모두 단어표 값

Port Entity Matching

0.8805 → 0.9163

공개 리더보드 점수

규칙 v2 대비 LLM 후보 채널 (테스트 50%, 진행 중)

운영 기록

> **수치를 읽는 법**
>
> 모든 수치에 측정 방식을 표시했습니다. 실계좌 수익, 대회 순위, 수상(Emori 팀 논문 제외)은 싣지 않았습니다. 근거는 각 저장소 README에 있습니다.

프로젝트

01 Emori 팀 완료

뇌파·감정을 상담 문장으로 바꾸는 모델의 학습 데이터와 파인튜닝

2025.09 ~ 2025.12 · 뇌파 전처리, 학습 데이터(증강·정답 문장), 모델 파인튜닝 담당. 인터뷰 키워드 분석과 연관 분석 대시보드는 팀원 담당.

50세트 증강 학습 데이터
규칙 기반, 감정·강도 값은 모두 단어표 값

168 / 42 학습 / 검증 분할
80 : 20, 에폭마다 검증

github.com/KTHYEONG/Emori

02 Witches-Chat-Core 팀 완료

학사 규정을 검색용 Markdown으로 구조화한 RAG 전처리

2026.03 ~ 2026.06 · 담당은 문서 변환·구조 표시·표/양식 분리·변환 점검. 청킹·검색·가드레일·인프라는 팀원 담당(커밋 37개, processors.py 952줄 중 546줄, git blame 기준).

Markdown 28개 정리된 규정 문서
HWP 20·DOCX 5·PDF 4개에서 변환(중복 형식 포함)

비공개 저장소

03 Port Entity Matching 개인 진행 중

규칙으로 못 푸는 한글 선박명을 LLM 후보로 보완한 대회

2026.10 ~ 진행 중 · 정규화, 후보 검색, 특징, 랭커, 평가 도구, 제출 코드를 단독 설계·구현했습니다.

0.8805 → 0.9163 공개 리더보드 점수
규칙 v2 대비 LLM 후보 채널 (테스트 50%, 진행 중)

운영 기록

비공개 저장소

사례

CASE 01 Emori 팀

템플릿·범용 LLM 대신 파인튜닝 선택

원본 통합	증강	정답 작성	LoRA 학습	리포트
뇌파·VR TXT를 JSON으로	규칙 기반 50세트	4문체 280개	Llama 3.1 8B	서술형 요약 생성

P 문제 뇌파 지표는 숫자라 읽기 어렵습니다. 협력 기업과 정해진 형식의 서술형 답변으로 합의했습니다.

A 분석
- 규칙 템플릿: 문장 반복, 지표 단위 해석이라 제외
- 범용 LLM: 도메인 표현 부족, 일반론이라 제외
- 데이터 100개 이하: 파인튜닝 + 증강 + 다문체 정답

A 실행
- Llama 3.1 8B Instruct 4비트(NF4) 양자화
- LoRA r=32, alpha=16, 대상 q_proj/v_proj
- 에폭 7, 배치 1 x 누적 8, 학습률 3e-4(cosine), RTX 4070 Ti
- 변환부터 요약 생성까지 단일 파이프라인

R 결과 체험 시작·중간·마지막 3단계를 각각 한 문장으로 서술. 정량 평가 없이 생성 문장을 직접 읽어 확인.

CASE 02 Emori 팀

비현실적 조합을 막는 증강 규칙 설계

P 문제 학생 데이터가 적어 증강이 필요했습니다.

A 분석
- 무작위 생성: 스트레스·이완 동시 상승 등 비현실 조합, 제외
- 러셀 감정 이론 등 참고, 지표 간 관계 규칙화

A 실행
- 처음 9세트: 제공 기록의 흐름 유지
- 나머지: +-20% 범위에서 생성
- 스트레스는 이완 반대 방향, 극단 조합 빈도 제한
- 시드 고정, 값 이름(Full/Half/Low 등) 원본 기준 통일 후 재생성

R 결과 50세트 생성, 감정·강도 값 모두 단어표 값 확인. 실제 데이터와의 유사도는 미검증.

CASE 03 Witches-Chat-Core 팀

HWP·DOCX·PDF를 Markdown 하나로 통일

규정 원본	형식별 변환	구조 표시	노이즈 정리	청킹 전달
HWP·DOCX·PDF	변환기 등록	조·항·호 기호	제어문자·표	블록 정보 포함

P 문제 규정이 세 형식으로 섞여 있고 조·항·호 계층이 의미를 정합니다. 형식별로 다루면 청킹·검색이 형식에 묶입니다.

A 분석
- 형식별 청킹: 팀원이 입력을 따로 처리해야 해 제외
- Markdown: 청킹 표준 입력, 제목·목록·표 표현 가능
- 팀원 모두 같은 입력 형식 사용 가능

A 실행
- 형식별 변환기 등록, 같은 출력 구조
- 초기에는 HWP를 DOCX로 수동 변환
- 이후 HWP 직접 변환 추가

R 결과 원본 HWP 20·DOCX 5·PDF 4개를 Markdown 28개로 정리해 청킹 단계에 전달.

원본 형식과 변환 결과 개



형식별 원본 파일 수와 Markdown 변환 결과

CASE 04 Witches-Chat-Core 팀

표와 신청서 양식을 구분해 본문에서 분리

P 문제 신청서 서식과 빈 칸 많은 표가 본문에 섞이면 검색이 오염되고 청킹이 어렵습니다.

A 분석
- 표 일괄 처리: 내용 표와 양식 구분 불가, 제외
- 빈 칸 비율 등 구조 단서와 양식 표현으로 판별

A 실행
- 빈 칸 많은 다열 표, 양식 표현(예/아니오), 지정 패턴이면 양식 판별
- 양식은 본문과 따로 변환
- 청킹이 표를 별도 임베딩 가능

R 결과 양식 표가 본문과 분리되어 청킹 단계로 전달. 판별 정확도는 미측정.

CASE 05 Port Entity Matching 개인

한글 선박명, 규칙 소리 키 + LLM 후보로 분담

정규화	후보 검색	LLM 표기	랭커	재순위	선박 1척
이름 정리	소리 키 + 톤수 창	라틴 후보 추가	LightGBM lambdarank	한글 상위 10개	vessel_id 확정

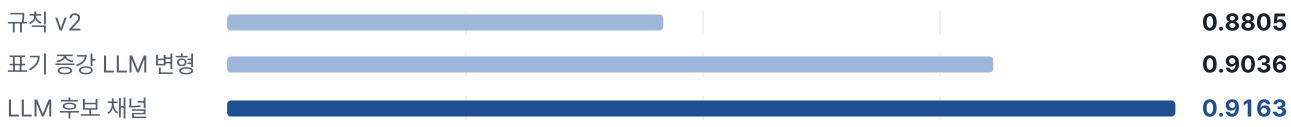
P 문제 한글 이름은 차용어·로마자·약어 읽기가 섞여 규칙 하나로 못 맞춥니다. 한글 행은 데이터의 약 9.7%, 점수의 70%입니다.

A 분석
- 표준 로마자 표기만 사용: 한글 오류 24건에서 63건, 제외
- 자음·모음 소리 키 채택 + 차용어 규칙(묵음 R, 어두 H, 모음 Y)
- 한글 오류 23건에서 14건 (5개 시드 평균)
- 미학습 표기에 약해 LLM 라틴 표기 채널 추가

A 실행
- 소리 키 + 톤수 창(±25%) 후보에 Kanana 후보 합산
- LLM은 후보만 확장, 최종 판단은 랭커
- 한글 행 상위 10개 LLM 우도 재순위

R 결과 리더보드 규칙 v2 0.8805, LLM 후보 채널 0.9163(한글 479/532, 비한글 1701/1784). 표기 증강 LLM 변형은 0.9036이라 되돌렸습니다. 운영 기록

공개 리더보드 점수 점수 운영 기록



같은 제출 방식의 리더보드 점수. 표기 증강 변형은 되돌림 (막대 시작값 0.85)

기술 · 기타

사용한 기술

Python · Llama 3.1 8B · Transformers · TRL · PEFT(LoRA) · bitsandbytes · pandas · numpy · PyMuPDF · python-docx · rhwp-python · Open WebUI · Ollama · ChromaDB · LightGBM · RapidFuzz · scikit-learn · PyTorch

팀 프로젝트에서 제가 맡은 범위

Emori · 제가 맡은 일

- 뇌파·VR 결과 TXT를 JSON으로 통합하고 값·라벨 정리
- 규칙 기반 데이터 증강 50세트
- 정답 문장 4가지 문체 작성 (70세트 x 4문체 = 280개)
- Llama 3.1 8B LoRA 파인튜닝과 서술형 요약 생성

팀원 담당·팀 공통

상담 인터뷰 텍스트의 감정 키워드 추출(형태소 분석과 BERT 결합), 키워드와 감정의 연관 분석, 통합 대시보드는 팀원이 맡았습니다. 제 성과로 주장하지 않습니다.

Witches-Chat-Core · 제가 맡은 일

- HWP·DOCX·PDF 규정을 Markdown으로 변환하는 형식별 변환기
- 편·장·절·조·항·호·목을 Markdown 기호로 표시
- 제어문자·서식 노이즈 제거, 표와 양식을 본문에서 분리
- DOCX·PDF 변환 속도 개선, 변환 전후 글자 수 점검 로그
- 오피스·이미지·음성 변환 추가, 청킹용 블록 정보(chunk:block 주석) 전달

팀원 담당·팀 공통

청킹·임베딩·소속별 검색, 입력 가드레일, 출력 개인정보 마스킹, Open WebUI 연동, 서버·인프라는 팀원 담당. 블록 정보 형식은 팀원과 함께 정함.

AI 활용

AI 코딩 도구를 주로 코드를 쓰는 데 사용했고, 아이디어를 다듬거나 처음 접하는 분야를 공부할 때도 썼습니다. 수치와 동작은 직접 확인했고, 확인하지 못한 것은 성과로 쓰지 않았습니다.

AI에 맡긴 일	직접 한 일
코드 작성	결과 수치와 동작을 직접 확인
아이디어 정리와 도메인 학습 보조	확인하지 못한 내용은 성과로 쓰지 않기

프로젝트별 한계

- **Emori** 정량 평가 없음, 품질은 생성 문장을 직접 읽어 확인한 수준
- **Witches-Chat-Core** 전처리 구간 자동 테스트 없음, 글자 수 대조 로그(85% 미만 경고)와 육안 확인
- **Port Entity Matching** 0.9910은 LLM 채널 추가 전 값, 현재 코드 교차검증은 미측정

수치 기준 표기

백테스트 과거 데이터 시뮬레이션 · 재현 시뮬레이션 체결·증거금 규칙을 적용한 원장 리플레이 · 평가셋 측정 정해진 평가 데이터로 잰 값 · 팀 측정 팀 전체 측정값(제 기여분만의 값이 아님) · 운영 기록 실제로 돌린 기록

그 밖의 프로젝트

auto-mobility 실내 공간을 3D 모델로 복원하고 센서 데이터로 검증하는 온라인 현장실습 팀 프로젝트(3명). 저는 Visual SLAM 비교와 평가를 주로 맡았습니다.

K-Stock Engine 국내주식 다중 팩터 전략을 연구하고 가상 장부로 기록합니다. 아직 불완전한 단계라 성과는 싣지 않았습니다.

OIBC 2026 태양광 발전량 예측과 가상발전소(VPP) 배정 대회 프로젝트. 제출 전이라 점수는 싣지 않았습니다.

연락 xogud3624@gmail.com · github.com/KTHYEONG