AI / Digital / LLM·RAG 지원용 포트폴리오

김태형

TaeHyeong Kim

모델 앞의 데이터를 정리하고, 모델을 실제 시스템 안에서 쓰는 데까지 해 봤습니다

경북대학교 컴퓨터학부 · 2027.02 졸업 예정 · xogud3624@gmail.com · github.com/KTHYEONG

뇌파·인터뷰 데이터의 전처리와 LLM 파인튜닝(팀), 학사 규정 문서의 RAG용 구조화(팀), 시점 정합 피처와 LightGBM 앙상블을 실시간 시스템에 올린 개인 프로젝트를 했습니다. 팀 프로젝트에서 제가 맡은 범위는 각 항목에 구분해 적었습니다.

주요 역량

데이터 전처리와 품질 관리

형식과 라벨이 제각각인 EEG·텍스트·HWP 문서를 모델과 검색이 쓸 수 있는 입력으로 정리했습니다.

모델 파인튜닝

Llama 3.1 8B를 LoRA로 파인튜닝하고 학습/검증 분리로 결과를 비교했습니다.

머신러닝 검증

미래 정보 차단 피처, 모델·손실 함수 비교, CPCV, 재학습 승격 게이트로 모델을 교체해도 되는지 판단했습니다.

실제 시스템에서의 AI 활용

모델 추론을 데이터 수집·검증·실행 파이프라인에 넣어 매일 자동으로 돌렸습니다.

대표 프로젝트

01 Emori 팀

EEG와 인터뷰 텍스트를 다루는 멀티모달 팀 프로젝트, 데이터 전처리와 파인튜닝 담당

github.com/KTHYEONG/Emori

02 K-Closing Alpha 개인

ML 모델을 실제 매일 도는 시스템에 올리고, 교체 기준까지 만든 개인 프로젝트

github.com/KTHYEONG/k-closing-alpha

03 Witches-Chat-Core 팀

학사 규정 RAG 팀 프로젝트, 청킹 이전의 문서 전처리·구조화 담당

비공개 저장소

04 Port Entity Matching 개인

학습 랭커와 LLM을 후보 생성기로 쓴 매칭 대회 프로젝트 (개인, 대회 진행 중)

비공개 저장소

모든 수치에는 측정 방식(백테스트 · 재현 시뮬레이션 · 운영 기록 · README 기재)을 표시했고, 자세한 설명은 마지막 쪽에 있습니다.

PROJECT 01 팀 프로젝트

Emori

EEG(뇌파)와 상담 인터뷰 텍스트를 함께 분석하는 멀티모달 AI 프로젝트

역할	팀 프로젝트 · 담당: EEG·관련 데이터 전처리, Llama 3.1 8B 파인튜닝
기간	2025
수상	2025 한국정보기술학회 추계종합학술대회 우수논문상 (동상) · 팀 논문
기술	Python · PyTorch · Transformers · LoRA · scikit-learn
GitHub	github.com/KTHYEONG/Emori

제가 맡은 범위

- EEG 6개 지표와 감정·신체감각 데이터를 학습에 쓸 수 있는 형식으로 정제·구조화
- 데이터 형식과 라벨을 통일하고 노이즈를 정리해 모델 입력 데이터셋 구성
- 원본 EEG 패턴을 기반으로 학습 데이터 50개 세트 생성(데이터 증강)
- Llama 3.1 8B LoRA 파인튜닝, 학습/검증 80:20 분리, 결과 비교·개선
- 전처리 데이터와 모델 출력을 후속 분석·리포트 단계에서 쓰기 좋게 정리

팀 프로젝트 전체에서 제 기여가 아닌 부분

상담 발화 분석, 시맨틱 토픽망, Streamlit 대시보드, 임상 리포트 생성 등 시스템의 나머지 구성은 팀원이 구현했으며 이 자료의 성과로 주장하지 않습니다.

이 직무 관점 **EEG와 인터뷰 텍스트를 다루는 멀티모달 팀 프로젝트, 데이터 전처리와 파인튜닝 담당.** 서로 다른 형식의 데이터를 학습 가능한 형태로 통일하고, 그 위에 Llama 3.1 8B를 파인튜닝했습니다.

Emori는 아동·청소년 심리 상담에서 말로 표현된 감정과 신체 반응(뇌파)이 어긋나는 경우를 함께 살펴보기 위해 만든 팀 프로젝트입니다. 저는 그중 **데이터 전처리와 모델 파인튜닝** 파트를 맡았습니다.

정제한 EEG 지표
6개
감정·신체감각 데이터와 함께 학습 형식으로 구조화
README 기재

학습/검증 분리
80 : 20
Llama 3.1 8B LoRA 파인튜닝
README 기재

증강 학습 세트
50개
원본 EEG 패턴 기반
README 기재

핵심 판단과 해결

01 모델이 읽을 수 있는 입력으로 뇌파와 인터뷰 데이터를 맞추기

문제

EEG 로그와 인터뷰 텍스트는 형식과 라벨 기준이 서로 달랐고 노이즈도 섞여 있어, 그대로는 모델 학습에 쓸 수 없었습니다.

한 일

- 원시 데이터를 파싱해 EEG 지표 6개와 감정·신체감각 라벨을 한 형식으로 통일
- 노이즈를 정리하고 학습/검증을 80:20으로 나눠 평가 기준을 먼저 고정
- 원본 패턴을 바탕으로 학습 데이터 50개 세트를 만들어 양을 보완

결과

파인튜닝과 이후 리포트 단계가 같은 데이터 형식을 쓰게 되어, 전처리가 모델·분석 양쪽의 공통 입력이 되었습니다.

02 프로젝트 데이터에 맞춰 Llama 3.1 8B를 파인튜닝

문제

범용 모델은 EEG 지표와 인터뷰 맥락을 함께 해석하는 프로젝트 요구에 맞지 않았습니다.

한 일

- 전처리한 데이터셋으로 Llama 3.1 8B를 LoRA 방식으로 파인튜닝(저장소 문서는 4-bit QLoRA 추론 구성으로 설명)
- 검증 세트로 결과를 비교하고 개선 반복

결과

파인튜닝한 모델이 팀의 분석·리포트 단계에서 사용됩니다. 정량 성능 수치는 이 자료에 싣지 않았습니다.

한계

- 학습 데이터가 소규모 원본에서 증강한 50개 세트라, 일반화 성능을 주장하지 않습니다.
- 파인튜닝 전후의 정량 비교는 공개 자료로 확인한 값이 없어 수치를 쓰지 않았습니다.
- 저장소 README에는 팀 시스템 전체의 지표가 있으나, 개인 기여와 분리할 수 없어 이 자료에서는 인용하지 않았습니다.

배운 점

모델 성능보다 앞서 데이터 형식과 라벨 기준, 평가 분리를 정하는 것이 결과를 해석 가능하게 만든다는 점을 배웠습니다.

PROJECT 02 개인 프로젝트

K-Closing Alpha

15:20에 알 수 있는 정보만으로 종목을 고르고, 종가에 사서 다음 날 시초가에 파는 국내주식 퀀트 시스템

역할	기획·데이터 수집·피처·모델·검증·주문 실행 로직까지 전 과정을 단독 설계·구현
기간	2026
기술	Python · LightGBM · Pandas · PyArrow(Parquet) · aiohttp · Pydantic · pytest · systemd
GitHub	github.com/KTHYEONG/k-closing-alpha

이 직무 관점 **ML 모델을 실제 매일 도는 시스템에 올리고, 교체 기준까지 만든 개인 프로젝트.** 시점 정합 피처, 선형 대 트리 모델 비교, LightGBM 5시드 앙상블, 모델 교체 승격 게이트가 핵심입니다.

한국 시장의 장 마감 동시호가(15:20~15:30)는 기관·외국인의 포지션 정리와 패시브 수급이 몰려 하루 중 수급 불균형이 가장 큰 구간입니다. 그러나 이 구간을 백테스트하면 마감 후 확정되는 종가가 판단에 섞이기 쉽고, 저가주는 호가 비용과 거래세가 수익을 지우며, 10분 안에 데이터를 모아야 하는 현실적 제약도 있습니다.

검증 기간

886거래일

2023-01 ~ 2026-09 · 68,493개 일별 종목 단면

백테스트

일평균 순수익

+34.58bp

거래세·왕복 2틱 호가 비용·수수료 차감 후

백테스트

Sharpe

2.73

t-stat 5.12 · 일별 승률 56.3%

백테스트

탐색한 전략

118개

CPCV(8,2) 28개 경로 + 5거래일 엠바고로 비교

백테스트

모델과 손실 함수에 따른 일평균 순수익 bp/일 (순수익) 백테스트



같은 검증 틀(886거래일, 비용 차감)에서 비교한 대표 모델.

핵심 판단과 해결

01 15:30 종가를 15:20 판단에 섞지 않기

문제

백테스트에서 장 마감 후 확정되는 종가나 피처가 15:20 판단에 섞이면 수익률이 비현실적으로 좋아집니다. 이 프로젝트는 판단 시각(15:20)과 종가 확정 시각(15:30)이 10분 차이라 실수하기 쉬웠습니다.

한 일

- 15:20 관찰 가격(결정_종가)과 15:30 확정 종가를 서로 다른 컬럼으로 분리해 저장
- 과거 1분봉에서 15:20 시점의 상태를 복원하는 패널 빌더를 만들고, 피처마다 사용 가능 시각(available_by) 검증기 적용
- 판단은 15:20 정보로만, 체결은 종가 매수 → 다음 날 09:00 시초가 전량 청산으로 고정하고 사후 갭 필터는 금지

결과

문서 기준 미래 정보 참조율 0.00%. 수익률이 올라가는 사후 필터를 쓰지 않는 대신 결과가 보수적으로 나옵니다.

02 선형 모델은 비용을 못 넘고, 트리 모델은 넘는다

문제

호가 불균형·수급·예상체결 괴리 같은 변수는 서로 상호작용하는데, 어떤 모델과 손실 함수가 이를 비용 차감 후에도 살려내는지 몰랐습니다.

한 일

- ElasticNet·Huber(선형)와 ExtraTrees·LightGBM(트리)을 같은 검증 틀에서 비교
- 이상치에 둔감한 L1 손실, 하방 손실 가중 손실 등 목적 함수를 바꿔 가며 비교
- 운영 모델은 5개 시드 LightGBM 앙상블로 구성

결과

선형 모델은 -12.27 / -8.81bp로 비용을 넘지 못했고 트리 계열은 +17.98bp 이상이었습니다. 호가·수급 변수의 비선형 상호작용이 핵심이라는 판단 근거가 됩니다.

한계

- 118개 전략을 탐색한 뒤 고른 결과라 선택 편향이 남아 있습니다. CPCV와 엠바고로 줄였지만 없애지는 못했습니다.
- 표본이 약 3년 8개월의 한 시장입니다. 다른 국면에서의 재현은 확인하지 못했습니다.

PROJECT 03 팀 프로젝트

Witches-Chat-Core

대학 학사 규정을 검색 가능한 형태로 정리해 안전한 질의응답으로 연결하는 RAG 팀 프로젝트

역할	팀 프로젝트 · 담당: RAG 청킹을 위한 학사 규정 데이터 전처리, 문서 파싱·구조화
기간	2026
기술	Python · 문서 파싱(HWP·DOCX·PDF) · 데이터 전처리
GitHub	비공개 저장소

제가 맡은 범위

- HWP·DOCX·PDF 등 학사 규정 문서에서 불필요한 서식·양식·노이즈를 제거하고 본문 구조 정리
- 편·장·절·조·항·호·목 7단계 계층 구조와 예외 조건이 유지되도록 청킹 전 구조화
- 표와 양식 문서가 검색 결과를 오염시키지 않도록 실제 규정 본문과 분리
- 정제한 데이터를 후속 청킹·임베딩·검색 단계에서 바로 쓸 수 있는 형태로 전달

팀 프로젝트 전체에서 제 기여가 아닌 부분

청킹, 임베딩·검색, 접근 제어, 가드레일, LLM 응답 생성 등 RAG 서비스의 나머지 구성은 팀원이 구현했으며 이 자료의 성과로 주장하지 않습니다.

이 직무 관점 **학사 규정 RAG 팀 프로젝트, 청킹 이전의 문서 전처리·구조화 담당.** 7단계 규정 계층과 예외 조건을 보존해 청킹 가능한 데이터로 만드는 일을 했습니다.

학사 규정은 계층 구조가 깊고 예외 조건이 많아, 단순히 글자 수로 잘라서는 검색 가능한 지식이 되기 어렵습니다. 이 팀 프로젝트는 규정을 검색 가능한 지식으로 구성하고 안전한 LLM 응답으로 연결하는 RAG 시스템입니다. 저는 그중 **청킹 이전의 데이터 전처리와 문서 구조화**를 맡았습니다.

보존한 규정 계층
7단계
편·장·절·조·항·호·목
README 기재

처리한 문서 형식
HWP · DOCX · PDF
학사 규정 문서
README 기재

핵심 판단과 해결

01 규정의 계층과 예외 조건을 잃지 않고 청킹 가능한 데이터로 만들기

문제

규정은 조·항·호로 이어지는 계층 안에서 의미가 정해지고, "다만" 같은 예외 조건이 바로 뒤 문장에 붙습니다. 서식과 표를 함부로 정리하거나 문장 단위로 자르면 예외가 사라지거나 다른 조항과 섞입니다.

한 일

- 문서 형식별 파서로 원문을 추출한 뒤, 서식·머리글·양식 등 규정 내용이 아닌 요소를 제거
- 편·장·절·조·항·호·목의 7단계 계층을 인식해 각 문장이 속한 위치와 예외 조건이 함께 유지되도록 구조화
- 표와 양식은 본문과 분리해, 검색 결과에 노이즈로 섞이지 않게 함
- 파서는 DOCX의 XML을 직접 순회하고 제어문자를 걸러내 속도를 확보하고, 서식 표는 따로 격리(저장소 문서의 수집·파싱 단계 설명 기준)

결과

원문을 유지한 구조화 데이터가 팀의 청킹·임베딩 단계로 전달됩니다. 검색 정확도 같은 팀 시스템 지표는 개인 성과로 쓰지 않습니다.

한계

- 제가 맡은 범위는 전처리·구조화이고, 그 결과가 최종 검색·답변 품질에 준 영향을 분리해 측정하지는 않았습니다.
- 저장소가 비공개라 이 자료에서는 코드 링크를 제공하지 않습니다. 팀 전체 지표(가드레일 방어율, 지연시간 등)는 제 기여가 아니므로 인용하지 않았습니다.

배운 점

RAG 품질은 모델 이전에 문서를 어떤 단위로 자르고 무엇을 남기느냐에서 갈린다는 점을 배웠습니다.

PROJECT 04 개인 프로젝트

Port Entity Matching

오타와 누락이 섞인 입출항 기록을 7만 8천 척의 표준 선박 카탈로그에 연결하는 매칭 모델
(DACON 항만 AI 대회)

역할 정규화, 후보 검색, 학습 랭커, 평가 도구, LLM 음역 채널까지 대회 개인 참가로 단독 설계·구현

기간 2026.1

기술 Python · LightGBM(lambdarank) · LLM(Kanana·Qwen · 고정 가중치) · pytest · uv

GitHub 비공개 저장소

이 직무 관점 **학습 랭커와 LLM을 후보 생성기로 쓴 매칭 대회 프로젝트 (개인, 대회 진행 중).** 교차검증과 리더보드의 격차를 가설로 나눠 검증하고, LLM이 정답을 정하지 않고 후보만 만들게 설계했습니다.

로컬 교차검증 점수

0.9875

선박 단위로 분리한 5-fold · 한글명 0.9824 · 비한글명 0.9995 · 가중 0.7/0.3

백테스트

공개 리더보드 점수

0.8805 → 0.9163

LLM 음역 채널 적용 전후 · 공개 리더보드 (테스트의 50%) · 대회 진행 중

운영 기록

핵심 판단과 해결

01 교차검증 0.9875인데 리더보드는 0.8805였을 때

문제

로컬 검증과 리더보드의 격차가 컸습니다. 원인을 추측으로 고치면 대회 제출 횟수(하루 5회)만 낭비합니다.

한 일

- 영문명 기록만 제출해 리더보드에서 버킷별 점수를 역산(영문 약 0.913, 한글 약 0.867)해 문제를 한글명으로 좁힘
- 서빙 경로 불일치, 학습에 없던 선박, 톤수 잡음, 영문 오타의 네 가설을 각각 합성 데이터와 저장·로드 비교로 검증해 모두 기각

결과

가설 4개를 기각해 병목을 학습 데이터에 없는 한글 표기 일반화로 좁혔습니다. 이 진단이 다음 단계의 방향이 되었습니다.

한계

- 대회가 2026-11-02까지 진행 중이라 최종 순위와 비공개 리더보드 점수는 아직 없습니다.
- 교차검증(0.9875)과 리더보드(0.9163)의 격차는 아직 남아 있습니다. 한글 규칙을 학습 데이터 이름을 본 뒤에 작성해 로컬 점수가 낙관적일 수 있음을 문서에도 적었습니다.
- 서버 시간 예산은 L4 서버 실측이 아니라 로컬 GPU 기반 추정치이며, 대회 규칙상 데이터와 코드는 외부에 공유할 수 없어 저장소는 비공개입니다.

> **수치를 읽는 법**
>
> 모든 수치에는 측정 방식을 함께 표시했습니다. 「백테스트」는 과거 데이터 시뮬레이션, 「재현 시뮬레이션」은 원장 리플레이, 「README 기재」는 저장소 문서에 적힌 운영 기록입니다. 실계좌 수익이나 수상 실적은 이 자료에 포함하지 않았습니다.
>
> 백테스트 과거 데이터 백테스트 재현 시뮬레이션 체결·증거금 규칙을 적용한 원장 리플레이 운영 기록 저장소 README에 기재된 운영 기록 README 기재 저장소 문서에 기재된 값

그 밖의 프로젝트와 링크

K-Stock Engine	국내주식 실행 코어와 KIS·KRX·DART 연동을 분리한 모듈형 엔진. 과거 연구 코드는 legacy/로 격리했습니다.
OIBC 2026	태양광 발전량 예측과 포트폴리오 최적화 챌린지 프로젝트. 진행 중이라 검증된 성과는 싣지 않았습니다.
ETF-Manager	월 적립식 ETF 자산배분 연구(S&T / 퀀트 자료에 요약 수록).

연락 xogud3624@gmail.com
GitHub https://github.com/KTHYEONG
금융·퀀트 Notion https://sparkly-quince-4ff.notion.site/Portfolio-3c996e29c4cf80c38b09ea1cca9a1cb4
AI Notion https://sparkly-quince-4ff.notion.site/AI-Portfolio-3e396e29c4cf810aaa44df3204963b41