AI · LLM 데이터 포트폴리오

김태형

TaeHyeong Kim

모델이 배우는 문장과 검색할 문서를 직접 설계했습니다

경북대학교 컴퓨터학부 · 2027.02 졸업 예정 · xogud3624@gmail.com · github.com/KTHYEONG

AI 프로젝트 세 개에서 모델 앞단의 데이터를 맡았습니다. Emori는 상담 문장 생성 모델의 학습 데이터(팀), Witches는 학사 규정 검색용 문서 구조화(팀), Port Entity Matching은 한글 선박명 매칭 대회(개인)입니다. 팀 프로젝트는 제가 맡은 부분과 팀 전체 결과를 나눠 적었습니다.

핵심 역량

문서 전처리와 구조화

HWP·DOCX·PDF를 Markdown 하나로 통일하고, 조·항·호 계층을 표시해 청킹이 조항 경계를 알게 했습니다.

학습 데이터 설계

증강 규칙과 정답 문장의 문체를 직접 정하고, 부자연스러운 문체는 학습에서 뺐습니다.

평가와 한계의 정직한 표기

팀 전체 지표에는 팀 라벨을 붙이고, 평가 데이터가 작아 흔들리는 점수는 통계 기준으로 판단했습니다.

대표 결과

Emori

50세트

증강 학습 데이터

규칙 기반 생성, 감정·강도 값은 모두 단어표 값

코드로 확인

Witches-Chat-Core

98.46%

팀 가드레일 공격 차단율

직접 만든 악성 입력 130개 중 128개 차단(논문 기준). 팀 전체 결과

팀 측정

Port Entity Matching

0.8805 → 0.9163

공개 리더보드 점수

규칙 기반 v2 대비 LLM 후보 채널 제출 (테스트 50%, 대회 진행 중)

운영 기록

> **수치를 읽는 법**
>
> 모든 수치에는 측정 방식을 함께 표시했습니다. 실계좌 수익이나 대회 순위, 수상 실적(Emori 팀 논문 제외)은 이 자료에 포함하지 않았습니다. 자세한 근거와 실행 방법은 각 저장소 README에 있습니다.

프로젝트 한눈에 보기

01 Emori 팀 완료

뇌파·감정을 상담 문장으로 바꾸는 모델의 학습 데이터 설계와 파인튜닝

2025.09 ~ 2025.12 · 내 담당은 뇌파 전처리, 학습 데이터(증강·정답 문장), 모델 파인튜닝입니다. 인터뷰 키워드 분석과 연관 분석 대시보드는 팀원이 맡았습니다.

50세트 증강 학습 데이터
규칙 기반 생성, 감정·강도 값은 모두 단어표 값
코드로 확인

280개 중 210개 사용 정답 문장
70세트 x 4문체 중 단순 나열 문체를 제외
코드로 확인

168 / 42 학습 / 검증 분할
80 : 20, 에폭마다 검증
코드로 확인

github.com/KTHYEONG/Emori

02 Witches-Chat-Core 팀 완료

학사 규정 문서를 검색용 Markdown으로 구조화한 RAG 전처리

2026.03 ~ 2026.06 · 내 담당은 문서 변환·구조 표시·표/양식 분리·변환 점검이고, 청킹·검색·가드레일·서비스 인프라는 팀원이 구현했습니다(저장소 커밋 37개, git blame 기준 processors.py 952줄 중 546줄).

Markdown 28개 정리된 규정 문서
HWP 20·DOCX 5·PDF 4개 원본에서 변환(같은 규정이 여러 형식인 경우 포함)
코드로 확인

98.46% 팀 가드레일 공격 차단율
직접 만든 악성 입력 130개 중 128개 차단(논문 기준). 팀 전체 결과
팀 측정

비공개 저장소

03 Port Entity Matching 개인 진행 중

규칙으로 풀기 어려운 한글 선박명을 LLM 후보로 보완한 대회 (진행 중)

2026.10 ~ 진행 중 · 개인 참가로 정규화, 후보 검색, 특징, 랭커, 평가 도구, 제출 코드를 단독 설계·구현했습니다.

0.9910 로컬 교차검증 점수
선박 단위 5-fold, 최종 채택 설정(LLM 채널 추가 전 번들)
백테스트

0.8805 → 0.9163 공개 리더보드 점수
규칙 기반 v2 대비 LLM 후보 채널 제출 (테스트 50%, 대회 진행 중)
운영 기록

비공개 저장소

문제 해결 사례

CASE 01 Emori 팀

규칙 템플릿도, 범용 LLM도 아닌 파인튜닝을 선택한 이유

원본 통합	증강	정답 작성	LoRA 학습	리포트
뇌파·VR TXT를 JSON으로	규칙 기반 50세트	4문체 280개	Llama 3.1 8B	서술형 요약 생성

P 문제

뇌파 지표는 숫자라 상담자가 바로 읽기 어려워, 협력 기업과 협의해 정해진 형식에 가까운 서술형 답변을 만드는 방향으로 정했습니다.

A 분석

- 규칙 기반 템플릿은 문장이 반복적이고 지표를 하나씩만 해석해, 여러 지표가 함께 움직이는 패턴을 못 담아 제외했습니다.
- LLM을 그대로 호출하면 도메인 표현이 부족하고 일반적인 말만 해서 제외했습니다.
- 학습 가능한 데이터가 100개 이하라, 파인튜닝에 데이터 증강과 여러 문체의 정답을 결합하기로 했습니다.

A 실행

- Llama 3.1 8B Instruct를 4비트(NF4) 양자화하고 LoRA(r=32, alpha=16, 대상 q_proj/v_proj)로 학습했습니다.
- 에폭 7, 배치 1 x 누적 8, 학습률 3e-4(cosine)로 개인 PC(RTX 4070 Ti)에서 학습했습니다.
- 변환부터 요약 생성까지 한 번에 실행하는 파이프라인을 구성했습니다.

R 결과 코드로 확인

체험 시작, 중간, 마지막 3단계를 각각 한 문장으로 서술하는 요약이 생성됩니다. 정량 평가는 하지 않았고 생성 문장을 직접 읽어 확인했습니다.

CASE 02 Emori 팀

비현실적인 조합이 생기지 않도록 증강 규칙을 직접 정한 이유

P 문제

제공받은 학생 데이터가 적어 증강이 필요했습니다.

A 분석

- 단순 무작위 생성은 스트레스와 이완이 함께 높은 식의 비현실적인 조합을 만들어 제외했습니다.
- 정서 이론(러셀의 감정 이론 등)을 처음 공부하며 참고해, 지표 간 관계를 반영하는 규칙을 직접 정했습니다.

A 실행

- 처음 9세트는 제공받은 기록의 흐름을 유지하고, 나머지는 +-20% 범위에서 생성했습니다.
- 스트레스는 이완의 반대 방향으로 만들고, 서로 어긋나는 극단 조합의 빈도를 제한했습니다.
- 시드를 고정해 재현할 수 있게 했고, 코드와 단어표의 값 이름(Full/Half/Low 등)을 원본 기준으로 통일해 증강 JSON을 다시 만들었습니다.

R 결과 코드로 확인

50세트를 생성했고 감정 종류와 강도 값이 모두 단어표에 있는 값임을 확인했습니다. 실제 사람 데이터와의 유사도는 검증하지 못했습니다.

CASE 03 Witches-Chat-Core 팀

HWP·DOCX·PDF가 섞인 규정을 형식별로 처리하지 않고 Markdown 하나로 통일했다

규정 원본	형식별 변환	구조 표시	노이즈 정리	청킹 전달
HWP·DOCX·PDF	변환기 등록	조·항·호 기호	제어문자·표	블록 정보 포함

P 문제

규정이 세 가지 형식으로 섞여 있고 조·항·호 계층이 의미를 정합니다. 형식마다 따로 다루면 청킹과 검색이 형식에 묶입니다.

A 분석

- 형식별로 각각 청킹하는 방안은 팀원이 형식마다 입력을 따로 처리해야 해서 제외했습니다.
- Markdown은 청킹 단계의 표준 입력 형식이고 제목·목록·표를 표현할 수 있어 LLM이 읽기에도 좋아 선택했습니다.
- 팀원 모두가 같은 입력 형식을 쓸 수 있다는 점도 판단에 반영했습니다.

A 실행

- 파일 형식별 변환기를 등록해 어떤 형식이든 같은 출력 구조를 내게 했습니다.
- 처음에는 HWP를 DOCX로 수동 변환해 시작했고, 이후 HWP 직접 변환을 추가했습니다.

R 결과 코드로 확인

규정 원본 HWP 20·DOCX 5·PDF 4개가 Markdown 28개로 정리되어 청킹 단계로 넘어갑니다.

CASE 04 Witches-Chat-Core 팀

의미 있는 표와 신청서 양식을 구분해 본문에서 분리했다

P 문제

규정 문서에는 신청서 서식과 빈 칸이 많은 표가 섞여 있어, 본문과 섞이면 검색 결과를 오염시키고 청킹도 어려워집니다.

A 분석

- 표를 모두 같은 방식으로 다루면 실제 내용을 담은 표와 양식을 구분할 수 없어 제외했습니다.
- 빈 칸 비율 같은 구조 단서와 양식 표현으로 양식을 판별하는 방식을 선택했습니다.

A 실행

- 빈 칸이 많은 다열 표, 양식에 쓰는 표현(예: 예/아니오), 지정한 패턴이 있으면 양식으로 판별했습니다.
- 양식은 본문과 따로 변환해 넘기고, 청킹 단계가 표를 별도 임베딩으로 처리할 수 있게 했습니다.

R 결과 코드로 확인

양식 표가 규정 본문과 분리되어 청킹 단계로 넘어갑니다. 판별 규칙의 정확도는 따로 측정하지 못했습니다.

CASE 05 Port Entity Matching 개인

규칙으로 풀기 어려운 한글 선박명을, 규칙 소리 키와 LLM 후보로 나눠 푼 사례

정규화	후보 검색	LLM 표기	랭커	재순위	선박 1척
이름 정리	소리 키 + 톤수 창	라틴 후보 추가	LightGBM lambdarank	한글 상위 10개	vessel_id 확정

P 문제

한글 이름은 리플렉션(차용어), 흥아(로마자), 에스티아이(약어 읽기)가 섞여 표기 규칙 하나로 맞추기 어렵습니다. 한글 행은 학습 데이터의 약 9.7%지만 점수의 70%입니다.

A 분석

- 표준 로마자 표기만 쓰면 소리 분류 키 대비 한글 오류가 24건에서 63건으로 늘어 제외했습니다.
- 한글을 자음·모음 소리 키로 바꿔 비교하는 방식을 채택하고, 차용어 규칙(묵음 R, 어두 H, 모음 Y)을 더하자 한글 오류가 23건에서 14건으로 줄었습니다(5개 시드 평균).
- 규칙만으로는 처음 보는 표기에 약해, LLM이 라틴 표기를 생성하는 채널을 검색 단계의 보조로 추가했습니다.

A 실행

- 한글 소리 키와 톤수 창(±25%)으로 후보를 모으고, Kanana 1.5 2.1B가 만든 라틴 표기로도 후보를 모아 합쳤습니다.
- LLM은 후보만 늘리고 최종 판단은 항상 랭커가 하도록 했습니다. 한글 행에는 상위 10개를 LLM 우도로 보정하는 재순위를 더했습니다.

R 결과 운영 기록

규칙 기반 v2는 공개 리더보드 0.8805였고, LLM 후보 채널을 넣은 제출은 0.9163(한글 479/532, 비한글 1701/1784)이었습니다. 표기 증강을 넣은 LLM 변형은 0.9036으로 낮아 되돌렸습니다. 공개 리더보드는 테스트의 50% 기준이며 최종 순위는 대회 종료 후 정해집니다.

추가 근거

사용한 기술

Python · Llama 3.1 8B · Transformers · TRL · PEFT(LoRA) · bitsandbytes · pandas · numpy · PyMuPDF · python-docx · rhwp-python · Open WebUI · Ollama · ChromaDB · LightGBM · RapidFuzz · scikit-learn · PyTorch

팀 프로젝트에서 제가 맡은 범위

Emori · 제가 맡은 일

- 뇌파·VR 결과 TXT를 JSON으로 통합하고 값·라벨 정리
- 규칙 기반 데이터 증강 50세트
- 정답 문장 4가지 문체 작성 (70세트 x 4문체 = 280개)
- Llama 3.1 8B LoRA 파인튜닝과 서술형 요약 생성

팀원 담당·팀 공통

상담 인터뷰 텍스트의 감정 키워드 추출(형태소 분석과 BERT 결합), 키워드와 감정의 연관 분석, 통합 대시보드는 팀원이 맡았습니다. 이 자료에서는 제 성과로 주장하지 않습니다.

Witches-Chat-Core · 제가 맡은 일

- HWP·DOCX·PDF 규정을 Markdown으로 변환하는 형식별 변환기
- 편·장·절·조·항·호·목을 Markdown 기호로 표시
- 제어문자·서식 노이즈 제거, 표와 양식을 본문에서 분리
- DOCX·PDF 변환 속도 개선, 변환 전후 글자 수 점검 로그
- 오피스·이미지·음성 변환 추가, 청킹용 블록 정보(chunk:block 주석) 전달

팀원 담당·팀 공통

청킹, 임베딩, 소속별 검색, 입력 가드레일, 출력 개인정보 마스킹, Open WebUI 연동과 서버·인프라는 팀원이 맡았습니다. 청킹용 블록 정보 형식은 팀원과 함께 정했습니다.

개발 과정에서의 AI 활용

AI 코딩 도구를 주로 코드를 쓰는 데 사용했고, 아이디어를 다듬거나 처음 접하는 분야를 공부할 때도 썼습니다. 수치와 동작은 직접 확인했고, 확인하지 못한 것은 성과로 쓰지 않았습니다.

AI에 맡긴 일	직접 한 일
코드 작성	결과 수치와 동작을 직접 확인
아이디어 정리와 도메인 학습 보조	확인하지 못한 내용은 성과로 쓰지 않기

프로젝트별 한계

- **Emori** 파인튜닝 결과의 정량 평가(정확도, 손실 곡선 비교 등)를 하지 않았고, 품질은 생성 문장을 직접 읽어 확인한 수준입니다.
- **Witches-Chat-Core** 전처리 구간에는 자동 테스트가 없어, 변환 결과는 글자 수 대조 로그(85% 미만이면 경고만 남김)와 눈으로 확인했습니다.
- **Port Entity Matching** 로컬 점수 0.9910은 LLM 채널을 넣기 전 번들의 값이고, LLM 채널을 포함한 현재 코드의 교차검증 점수는 아직 측정하지 않았습니다. 대회 진행 중이라 최종 순위도 없습니다.

수치 기준 표기

백테스트 과거 데이터 시뮬레이션 · 재현 시뮬레이션 체결·증거금 규칙을 적용한 원장 리플레이 · 평가셋 측정 정해진 평가 데이터로 잰 값 · 팀 측정 팀 전체 측정값(제 기여분만의 값이 아님) · 운영 기록 실제로 돌린 기록 · 코드로 확인 코드·설정·테스트로 확인한 설계 사실

그 밖의 프로젝트

auto-mobility 실내 공간을 3D 모델로 복원하고 센서 데이터로 검증하는 온라인 현장실습 팀 프로젝트(3명). 저는 Visual SLAM 비교와 평가를 주로 맡았습니다.

K-Stock Engine 국내주식 다중 팩터 전략을 연구하고 가상 장부로 기록합니다. 아직 불완전한 단계라 성과는 싣지 않았습니다.

OIBC 2026 태양광 발전량 예측과 가상발전소(VPP) 배정 대회 프로젝트. 제출 전이라 점수는 싣지 않았습니다.

연락 xogud3624@gmail.com · github.com/KTHYEONG