AI · LLM 데이터 포트폴리오

김태형

TaeHyeong Kim

LLM이 학습하고 검색할 데이터를 설계했습니다

경북대학교 컴퓨터학부 · 2027.02 졸업 예정
xogud3624@gmail.com · github.com/KTHYEONG · kthyeong.github.io

Emori(팀)는 상담 문장 모델의 학습 데이터, Witches(팀)는 학사 규정 검색용 문서 구조화, Port Entity Matching(개인)은 한글 선박명 매칭으로 대회 468명 중 106위를 기록했습니다. 팀 프로젝트는 제 담당과 팀 전체 결과를 나눠 적었습니다.

프로젝트

01 Emori 팀 완료

뇌파·감정을 상담 문장으로 바꾸는 모델의 학습 데이터와 파인튜닝

50세트
규칙으로 늘린 학습 데이터

210개
정답 문장 (280개 중 사용)

168 / 42
학습 / 검증 분할

02 Witches-Chat-Core 팀 완료

학사 규정을 검색용 Markdown으로 구조화한 RAG 전처리

3형식 → Markdown
HWP·DOCX·PDF 규정을 하나로 통일

조·항·호 구조 표시
계층을 기호로 남겨 문서 쪼개기에 전달

표·양식 분리
본문과 구분해서 전달

98.46%
악성 질문 차단 (팀 전체, 130개 중 128개)

03 Port Entity Matching 개인 완료

규칙으로 못 푸는 한글 선박명을 LLM 후보로 보완한 대회

0.91989 · 106위
비공개 리더보드 최종 (468명 중)

0.8805 → 0.9595
공개 리더보드 점수

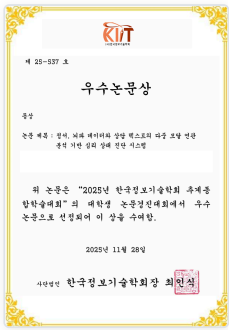
17 / 41건
역방향 채널로 해소 확인한 한글 오류

> **도움말**
>
> 모든 수치에 측정 방식을 표시했습니다. 실계좌 수익과 수상(Emori 팀 논문 제외)은 싣지 않았습니다. 대회 순위는 종료 후 확정된 비공개 리더보드 기준이고, 아직 결과가 나오지 않은 대회는 점수를 싣지 않았습니다. 근거는 각 저장소 README에 있습니다.

Emori 팀 완료

뇌파·상담 텍스트 멀티모달 AI, 뇌파 요약 LLM 담당

VR 체험 중 뇌파와 상담 인터뷰 텍스트를 함께 분석해 상담자가 학생 상태를 빠르게 파악하도록 돕는 산학협력 프로젝트입니다(협력기관 (주)모티버). 저는 수치 뇌파 지표를 서술형 리포트로 바꾸는 부분을 맡아, 100개 이하의 데이터를 규칙으로 늘리고 Llama 3.1 8B를 경량 추가학습 방식으로 파인튜닝했습니다.



KIT

제 25-537 호

우수논문상

증상

논문 제목 : 합비, 뇌파 데이터와 상담 텍스트의 다중 모달 연관 분석 기반 심리 상태 진단 시스템

위 논문은 "2025년 한국정보기술학회 추계종합학술대회" 의 대학생 논문경진대회에서 우수논문으로 선정되어 이 상을 수여함.

2025년 11월 28일

시상기관 한국정보기술학회장 최인석

기간 2025.09 ~ 2025.12

역할 뇌파 전처리, 학습 데이터 구축, Llama 3.1 8B 경량 추가학습(LoRA) (팀 프로젝트)

수상 2025 한국정보기술학회 추계종합학술대회 우수논문상(동상) · 팀 논문

기술 Python · Llama 3.1 8B · Transformers · TRL · PEFT(LoRA) · bitsandbytes · pandas · numpy

저장소 github.com/KTHYEONG/Emori

제가 맡은 일

- 뇌파·VR 결과 텍스트 파일을 하나의 JSON으로 통합, 값과 이름 정리
- 규칙 기반 데이터 증강 50세트
- 정답 문장 4가지 말투 작성 (70세트 x 4말투 = 280개)
- Llama 3.1 8B 경량 추가학습과 서술형 요약 생성

팀원 담당·팀 공통

상담 인터뷰 텍스트의 감정 키워드 추출(단어 분석과 문맥 이해 언어모델 결합), 키워드와 감정의 연관 분석, 통합 화면은 팀원이 맡았습니다. 제 성과로 주장하지 않습니다.

증강 학습 데이터
50세트
규칙으로 생성, 감정·강도 값은 모두 정해진 단어표 안의 값

정답 문장
280개 중 210개 사용
70세트 x 4말투, 단순 나열 제외

학습 / 검증 분할
168 / 42
80 : 20, 학습 한 바퀴마다 검증

결과 예시

뇌파 6지표가 요약 문장이 됩니다

입력 형식 (뇌파 지표 값)

스트레스	0.19
몰입	0.77
이완	0.76
흥분	0.48
흥미	0.81
집중	0.66

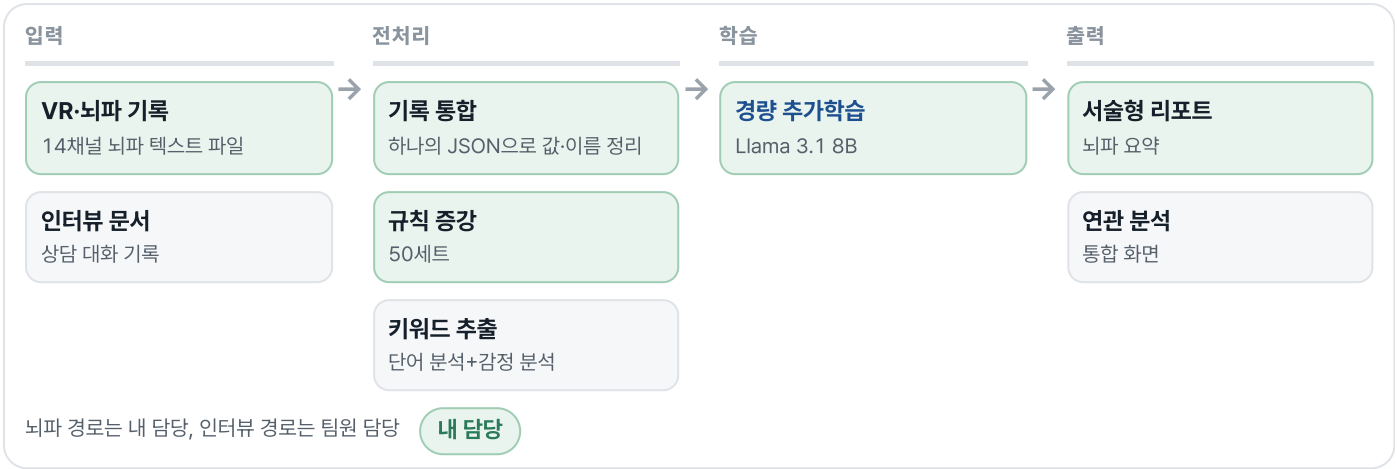
생성 예시 (일부 발췌)

"두 번째 단계에서는 스트레스가 매우 낮고 이완이 매우 높은 수준으로 상승하며 감정과 생체 지표 사이의 초기 대비가 형성됩니다."

Llama 3.1 8B (LoRA) 생성 문장 · 출처: Generated_Report.txt
입력 형식과 생성 예시를 각각 보여 주는 카드입니다

뇌파 6지표를 입력하면 모델이 요약 문장을 생성. 생성 문장은 일부 발췌(Llama 3.1 8B LoRA, 저장소 Generated_Report.txt)

구조



사례

CASE 01

규칙 문장·범용 LLM 대신 추가학습 선택

기록 통합	데이터 늘리기	정답 작성	추가학습	리포트
뇌파·VR 파일을 JSON으로	규칙으로 50세트	4가지 말투 280개	Llama 3.1 8B	서술형 요약 생성

P 문제

뇌파 지표는 숫자라 상담자가 바로 읽기 어렵습니다. 협력 기업과 정해진 형식의 서술형 문장으로 풀어 주기로 합의했습니다.

A 분석

- 규칙으로 만든 문장: 표현이 반복되고 지표를 하나씩만 해석해 제외
- 범용 LLM: 뇌파 분야 표현이 부족하고 일반론에 그쳐 제외
- 데이터 100개 이하: 파인튜닝 + 데이터 늘리기 + 여러 말투의 정답

A 실행

- 모델을 4비트로 줄여 적은 GPU 메모리로 학습
- 모델 일부 층에만 작은 추가 가중치를 붙여 학습(크기 32, 반영 비율 16)
- 학습 7바퀴, 1건씩 8건 모아 갱신, 학습 속도 3e-4, 개인용 GPU(RTX 4070 Ti)
- 기록 변환부터 요약 생성까지 한 흐름으로 실행

R 결과

체험 시작·중간·마지막 3단계를 각각 한 문장으로 서술. 정량 평가 없이 생성 문장을 직접 읽어 확인.

CASE 02

비현실적 조합을 막는 데이터 생성 규칙 설계

P 문제	학생 기록이 적어 그대로는 학습이 어려워, 규칙에 따라 가상 기록을 만들어 늘려야 했습니다.
A 분석	• 무작위 생성: 스트레스·이완이 함께 오르는 등 비현실 조합이 나와 제외 • 감정 이론(러셀 모형) 등을 참고해 지표 간 관계를 규칙으로 정리
A 실행	• 처음 9세트: 제공 기록의 흐름 유지 • 나머지: 원본 값의 위아래 20% 범위에서 생성 • 스트레스는 이완과 반대로 움직이게 하고 극단 조합은 드물게 제한 • 무작위 값 고정, 값 이름 표기를 원본 기준으로 통일한 뒤 다시 생성
R 결과	50세트 생성, 감정·강도 값이 모두 정해진 단어표 안의 값임을 확인. 실제 데이터와의 유사도는 미검증.

한계

- 정량 평가 없음, 품질은 생성 문장을 직접 읽어 확인한 수준
- 가상 기록과 실제 기록을 섞어 사용, 실제 분포와의 유사도 미검증
- 일부 감정 단어에 대응시킨 값은 협력 기업 기준과 맞는지 확인 필요

Witches-Chat-Core 팀 완료

근거 조항과 함께 답하는 온프레미스 규정 RAG 챗봇

경북대 학사 규정은 한글(HWP)·워드(DOCX)·PDF로 흩어져 있고, 클라우드 AI에는 규정과 개인정보를 보내기 어렵습니다. 학교 안에서 규정을 검색해 근거와 함께 답하는 챗봇을 팀으로 만들었고, 저는 앞단인 규정 문서를 Markdown으로 바꾸고 조·항 구조를 표시하는 일을 맡았습니다.

기간 2026.03 ~ 2026.06

역할 팀 프로젝트(5명) · 규정 문서 Markdown 변환 담당

기술 Python · PyMuPDF · python-docx · rhwp-python · Open WebUI · Ollama · ChromaDB

저장소 비공개 저장소

제가 맡은 일

- HWP·DOCX·PDF 규정을 Markdown으로 변환하는 형식별 변환기
- 편·장·절·조·항·호·목을 Markdown 기호로 표시
- 제어문자·서식 노이즈 제거, 표와 양식을 본문에서 분리
- DOCX·PDF 변환 속도 개선, 변환 전후 글자 수 점검 로그
- 오피스·이미지·음성 변환 추가, 문서 쪼개기에 쓸 구간 정보를 본문에 표시해 전달

팀원 담당·팀 공통

문서 쪼개기, 벡터 변환, 소속별 검색, 악성 질문 차단, 답변 속 개인정보 가리기, 채팅 화면 연동, 서버 구성은 팀원 담당. 구간 정보 형식은 팀원과 함께 정함.

정리된 규정 문서
Markdown 28개
HWP 20·DOCX 5·PDF 4개에서 변환(중복 형식 포함)

PDF 변환 시간(참고)
약 70초 → 15초
커밋 메시지 기록, 측정 환경 기록 없음
운영 기록

팀 악성 질문 차단율
98.46%
직접 만든 악성 입력 130개 중 128개 차단(논문 기준), 팀 전체 결과
팀 측정

구조

문서 준비	저장	질문	답변
규정 원본 HWP·DOCX·PDF	**문서 쪼개기** 구간 단위로 분할	**악성 질문 차단** 규칙→유사도→언어모델	**로컬 LLM** 답변 생성
Markdown 변환 구조 표시·정리	**벡터 저장소** ChromaDB	**검색** 소속별 열람 권한 적용	**개인정보 가리기** 답변 출력 단계

파란 구간이 제가 맡은 문서 전처리 **내 담당**

사례

CASE 01

HWP·DOCX·PDF를 Markdown 하나로 통일

규정 원본	형식별 변환	구조 표시	잡음 정리	쪼개기 전달
HWP·DOCX·PDF	형식마다 변환기	조·항·호 기호	깨진 문자 제거·표 분리	구간 정보 포함

P 문제 규정이 세 가지 파일 형식으로 섞여 있고, 조·항·호 계층이 의미를 정합니다. 형식별로 다루면 문서 쪼개기와 검색도 형식마다 따로 만들어야 합니다.

A 분석
- 형식별 문서 쪼개기: 팀원이 형식마다 따로 처리해야 해 제외
- Markdown: 문서 쪼개기의 표준 입력, 제목·목록·표 표현 가능
- 팀원 모두 같은 입력 형식 사용 가능

A 실행
- 형식별 변환기를 두되 결과 구조는 동일하게
- 초기에는 HWP를 DOCX로 수동 변환
- 이후 HWP 직접 변환 추가

R 결과 원본 HWP 20·DOCX 5·PDF 4개를 Markdown 28개로 정리해 문서 쪼개기 단계에 전달.

원본 형식과 변환 결과 개



형식별 원본 파일 수와 Markdown 변환 결과

CASE 02

표와 신청서 양식을 구분해 본문에서 분리

P 문제 신청서 서식과 빈 칸 많은 표가 본문에 섞이면 검색 결과에 불필요한 내용이 끼고 문서 쪼개기도 어렵습니다.

A 분석
- 표 일괄 처리: 내용 표와 양식 구분 불가, 제외
- 빈 칸 비율 등 표 모양과 양식 표현으로 판별

A 실행	• 빈 칸 많은 여러 열 표, 양식 표현(예/아니오), 정해 둔 글자 패턴이면 양식으로 판별 • 양식은 본문과 따로 변환 • 표를 따로 벡터로 변환해 저장 가능
R 결과	양식 표가 본문과 분리되어 문서 쪼개기 단계로 전달. 판별 정확도는 미측정.

한계

- 전처리 구간 자동 테스트 없음, 변환 전후 글자 수 비교 로그(85% 미만이면 경고)와 눈으로 확인
- 팀 악성 질문 차단 결과는 직접 만든 입력 210개 기준, 실제 질의 평가 아님
- 이미지 변환은 글자 인식(OCR) 도구 설치 후 검증 필요

Port Entity Matching

개인 · 완료

입출항 기록을 표준 선박 한 척으로 잇는 매칭 파이프라인

해양수산부 주최 DACON 항만 문제 해결 AI 대회에 개인으로 참가해, 비공개 리더보드 468명 중 106위(0.91989)로 마쳤습니다. 과제는 오타·한글 표기·빈 제원이 섞인 입출항 기록 한 줄을 약 7만 8천 척의 표준 선박 중 하나로 연결하는 것입니다. 한글 선박명이 점수의 70%라 한글 매칭에 집중했고, 발음 코드와 LLM 후보로 시작해 선박 카탈로그의 영문명을 한글로 바꿔 대조하는 역방향 채널까지 넣었습니다. 공개 점수는 0.8805에서 0.9595까지 올랐지만 비공개에서 0.04 낮아졌고, 그 원인은 분석하지 못했습니다.

기간 2026.10 ~ 2026.11

역할 대회 개인 참가, 후보 검색·순위 모델·평가 도구 단독 구현

기술 Python · LightGBM · RapidFuzz · scikit-learn · PyTorch · Kanana 1.5 2.1B · Midm 2.0 Mini · pytest · uv

저장소 github.com/KTHYEONG/port-entity-matching

비공개 리더보드 최종	공개 리더보드 점수	이름 변형 시험 점수	내부 검증 점수
0.91989	**0.8805 → 0.9595**	**0.8162 → 0.9477**	**0.9910**
468명 중 106위, 테스트 100% 기준 최종 순위 (대회 종료 2026.11.6)	테스트 50% 기준, 규칙 기반 대비 최종 제출물 (한글 507/532)	단어 순서 바꾸기·빼기 등 20가지 변형, 내 컴퓨터 모의 기준	선박 단위 5분할 검증, LLM 후보 추가 전 모델
운영 기록	운영 기록	백테스트	백테스트

구조



후보를 모은 뒤 랭커가 한 척을 고르는 구조

사례

CASE 01

한글 선박명, 발음 코드·LLM 후보·역방향 채널로 분담

정규화	후보 검색	LLM 표기	역방향 채널	순위 모델	재정렬	선박 1척
이름 정리	발음 코드 + 톤수 범위	영문 후보 추가	영문명→한글 변환 대조	후보별 순위 학습	한글 상위 10개	표준 선박 확정

P 문제

한글 이름은 영어 외래어, 한국어 로마자, 약어 읽기가 섞여 규칙 하나로 못 맞춥니다. 한글 행은 데이터의 약 9.7%, 점수의 70%입니다.

A 분석

- 표준 영문 변환만 사용: 한글 오류 24건에서 63건, 제외
- 발음 코드 채택: 한글을 자음·모음 소리 기호로 바꿔 비교 + 외래어 보정(발음 안 나는 R, 첫 글자 H, 모음 Y)
- 한글 오류 23건에서 14건 (5회 학습 평균)
- 처음 보는 표기에 약해 LLM 영문 표기 후보 추가
- 역방향 채널: 카탈로그 영문명을 LLM이 한글로 바꿔 자모로 대조, 당시 최고 모델의 한글 오류 41건 중 17건 해소 가능 확인
- 제외: 세 번째 한글 표기 생성(한글 정답 504), 합성 한글 행(501), 재순위 가중치 상향(500~502)

A 실행

- 발음 코드 + 톤수 ±25% 후보에 LLM 후보 합산
- LLM은 후보만 늘리고, 최종 판단은 순위 모델
- 한글 상위 10개를 LLM 가능성 점수로 재정렬
- 카탈로그 영문명을 두 LLM(Midm, Kanana)으로 한글 변환해 두고, 한글 행은 자모 상위 20척을 후보에 합산, 특징 3개 추가
- 학습에만 쓰는 변형 6종(이름 잘림, 표기 변형, 톤수 오류, 한글 자모 잡음 등)과 카탈로그 기반 합성 영문 행 15,000개

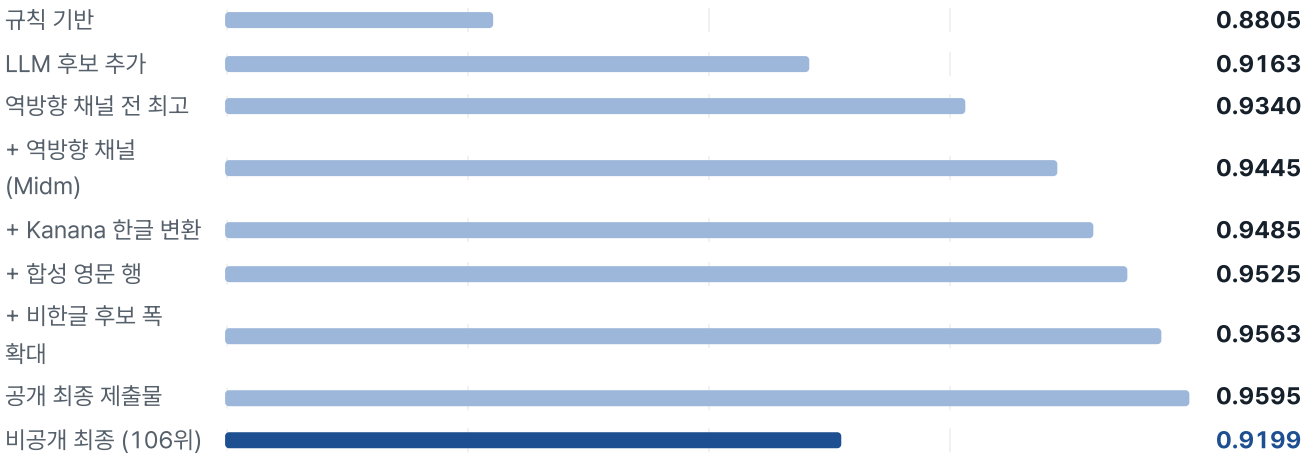
R 결과

공개 리더보드 0.8805(규칙 기반) → 0.9163(LLM 후보) → 0.9525(역방향 채널·합성 행, 한글 505/532, 비한글 1713/1784) → 0.9595(최종 제출물, 한글 507/532). 비공개 최종은 0.91989였습니다. 재학습 오차가 한글 ±2행, 비한글 ±4행이라 한글 3행 이상 개선만 인정했습니다. 운영 기록

한글 선박명 유형 (한글 → 정답 표기)

리플렉션	→	Reflection	영어 외래어
흥아	→	Heung-A	한국어 로마자
에스티아이	→	STI	약어 읽기

리더보드 점수 변화 점수 운영 기록



점수는 한글 0.7, 비한글 0.3 가중. 공개(테스트 50%) 단계별 값은 정답 행 수에서 환산, 마지막 막대만 비공개(100%) 최종 0.91989 (막대 시작값 0.85)

CASE 02

오르지 않는 지점에서 멈추고, 남은 한글 오류 25건의 원인 구분

P 문제 역방향 채널 뒤에도 한글 오류 25건이 남았습니다. 표기를 더 정확히 만들거나 모델을 키우면 줄어드는지 모른 채 시도만 늘리면 제출 횟수만 쓰게 됩니다.

A 분석

- 더 큰 LLM(Kanana-8B, A.X)으로 카탈로그 표기를 다시 생성: 표기 정확도는 62%에서 77%까지 올랐지만 점수는 그대로
- 다른 랭커, 선박 사전확률, 검색·재순위 범위 확대: 모두 효과 없음 또는 하락 (아래 표)
- 남은 오류는 이름이 거의 같은 자매선 중 어느 배인지 한 행만으로 정할 수 없는 경우가 대부분
- 같은 호출부호의 다른 기록을 모아 투표하면 학습 데이터에서 오류가 100개에서 6개로 줄지만, 다른 행을 쓰는 방식이라 대회 규칙상 제외

A 실행

- 표기·모델·랭커 확대 시도는 중단하고 미채택으로 기록
- 학습 선박만 답하는 제출을 만들어 정답이 0임을 확인, 테스트 선박은 학습 선박과 겹치지 않는다고 판단
- 호출부호 일치 없이 1위가 학습 선박이면 다음 학습 밖 후보로 교체, 대회 분할 구조를 이용한 규칙임을 문서에 명시
- 비한글 행의 후보 폭 확대와 학습 데이터의 단어 대응표·약어 읽기로 만든 표기 추가

R 결과 한글 정답 505에서 507, 점수 0.9525에서 0.9595(후보 폭 확대 0.9563, 학습 선박 제외 0.9581). 이후 시도는 모두 효과가 없었고, 비공개 최종은 0.91989였습니다. 운영 기록

리더보드로 확인한 시도 (한글 정답 수 변화)

더 큰 LLM 표기	→	**0 ~ −1**	표기 정확도 62→77%
CatBoost 랭커	→	**−3**	랭커 종류는 병목 아님
선박 사전확률	→	**−4**	비한글도 13행 하락
검색·재순위 확대	→	**0**	후보 범위는 병목 아님

한계

- 공개 0.9595가 비공개 0.91989로 약 0.04 낮아졌고, 원인은 분석하지 못함
- 내부 검증과 리더보드의 차이를 끝까지 설명하지 못함, 내 컴퓨터의 모의 오류로는 리더보드의 한글 오류가 재현되지 않음
- 0.9910은 LLM 후보 추가 전 값, 현재 코드의 내부 검증은 미측정

- 역방향 채널(카탈로그 이름을 미리 한글로 변환)은 규칙 허용 여부를 운영진에게 직접 확인받지 못함, 공식 답변은 학습 데이터 기반 LLM 증강까지이며 생성 코드·프롬프트는 검증 요청에 대비해 보관
- 학습 선박 제외는 대회 분할 구조를 이용한 규칙, 현장에서는 호출부호 기억이 그 역할
- 단어 하나 빠진 이름은 약함(영문 약 0.69, 한글 약 0.65, 모의 기준), 이름·톤수가 같은 자매선은 한 행만으로 구분 어려움
- 대회 데이터 재배포 금지로 저장소만으로는 학습·평가 재현 불가

기술 · 기타

사용한 기술

Python · Llama 3.1 8B · Transformers · TRL · PEFT(LoRA) · bitsandbytes · pandas · numpy · PyMuPDF · python-docx · rhwp-python · Open WebUI · Ollama · ChromaDB · LightGBM · RapidFuzz · scikit-learn · PyTorch

AI 활용

AI 코딩 도구를 주로 코드를 쓰는 데 사용했고, 아이디어를 다듬거나 처음 접하는 분야를 공부할 때도 썼습니다. 수치와 동작은 직접 확인했고, 확인하지 못한 것은 성과로 쓰지 않았습니다.

AI에 맡긴 일	직접 한 일
코드 작성	결과 수치와 동작을 직접 확인
아이디어 정리와 도메인 학습 보조	확인하지 못한 내용은 성과로 쓰지 않기

수치 기준 표기

백테스트 과거 데이터 시뮬레이션 · 재현 시뮬레이션 체결·증거금 규칙을 적용한 원장 리플레이 · 평가셋 측정 정해진 평가 데이터로 잰 값 · 팀 측정 팀 전체 측정값(제 기여분만의 값이 아님) · 운영 기록 실제로 돌린 기록

그 밖의 프로젝트

auto-mobility 실내 공간을 3D 모델로 복원하고 센서 데이터로 검증하는 온라인 현장실습 팀 프로젝트(3명). 저는 Visual SLAM 비교와 평가를 주로 맡았습니다.

K-Stock Engine 국내주식 다중 팩터 전략을 연구하고 가상 장부로 기록합니다. 아직 불완전한 단계라 성과는 싣지 않았습니다.

연락

xogud3624@gmail.com · github.com/KTHYEONG · kthyeong.github.io