AI · LLM 데이터 포트폴리오

김태형

TaeHyeong Kim

LLM이 학습하고 검색할 데이터를 설계했습니다

경북대학교 컴퓨터학부 · 2027.02 졸업 예정
xogud3624@gmail.com · github.com/KTHYEONG · kthyeong.github.io

Emori(팀)는 상담 문장 모델의 학습 데이터, Witches(팀)는 학사 규정 검색용 문서 구조화, Port Entity Matching(개인)은 한글 선박명 매칭으로 대회 468명 중 106위를 기록했습니다. 팀 프로젝트는 제 담당과 팀 전체 결과를 나눠 적었습니다.

프로젝트

01 Emori 팀 완료

뇌파·감정을 상담 문장으로 바꾸는 모델의 학습 데이터와 파인튜닝

70세트
학습 입력 (실제 45 + 증강 25, 증강은 기록 1개에서 파생)

210개
정답 문장 (280개 중 사용)

168 / 42
학습 / 검증 (레코드 단위 분할)

02 Witches-Chat-Core 팀 완료

학사 규정을 검색용 Markdown으로 구조화한 RAG 전처리

3형식 → Markdown
HWP·DOCX·PDF 규정을 하나로 통일

조·항·호 구조 표시
계층을 기호로 남겨 문서 쪼개기에 전달

표·양식 분리
본문과 구분해서 전달

98.46%
악성 질문 차단 (팀 전체, 130개 중 128개)

03 Port Entity Matching 개인 완료

규칙으로 못 푸는 한글 선박명을 LLM 후보로 보완한 대회

0.91989 · 106위
비공개 리더보드 최종 (468명 중)

0.8805 → 0.9595
공개 리더보드 점수

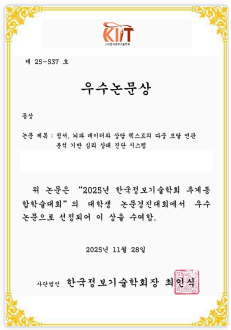
17 / 41건
역방향 채널로 해소 확인한 한글 오류

> **도움말**
> 모든 수치에 측정 방식을 표시했습니다. 실계좌 수익과 수상(Emori 팀 논문 제외)은 싣지 않았습니다. 대회 순위는 종료 후 확정된 비공개 리더보드 기준이고, 아직 결과가 나오지 않은 대회는 점수를 싣지 않았습니다. 근거는 각 저장소 README에 있습니다.

Emori 팀 완료

뇌파·상담 텍스트 멀티모달 AI, 뇌파 요약 LLM 담당

VR 체험 중 뇌파와 상담 인터뷰 텍스트를 함께 분석해 상담자가 학생 상태를 빠르게 파악하도록 돕는 산학협력 프로젝트입니다(협력기관 (주)모티버). 저는 수치 뇌파 지표를 서술형 리포트로 바꾸는 부분을 맡아, 실제 기록 45세트에 규칙 증강 25세트를 더한 70세트에 4가지 말투의 정답 문장을 작성하고 Llama 3.1 8B를 경량 추가학습 방식으로 파인튜닝했습니다.



우수논문상

2025년 11월 28일

한국정보기술학회장 최인석

기간 2025.09 ~ 2025.12

역할 뇌파 전처리, 학습 데이터 구축, Llama 3.1 8B 경량 추가학습(LoRA) (팀 프로젝트)

수상 2025 한국정보기술학회 추계종합학술대회 우수논문상(동상) · 팀 논문

기술 Python | Llama 3.1 8B | Transformers | TRL | PEFT(LoRA) | bitsandbytes | pandas | numpy

저장소 github.com/KTHYEONG/Emori

제가 맡은 일

- 뇌파·VR 결과 텍스트 파일을 하나의 JSON으로 통합, 값과 이름 정리
- 규칙 기반 데이터 증강(50세트 생성, 정답 문장이 있는 25세트를 학습에 사용)
- 정답 문장 4가지 말투 작성 (70세트 x 4말투 = 280개)
- Llama 3.1 8B 경량 추가학습과 서술형 요약 생성

팀원 담당·팀 공통

상담 인터뷰 텍스트의 감정 키워드 추출(단어 분석과 문맥 이해 언어모델 결합), 키워드와 감정의 연관 분석, 통합 화면은 팀원이 맡았습니다. 제 성과로 주장하지 않습니다.

학습 입력 세트
70세트
실제 기록 45 + 규칙 증강 25(증강은 50세트를 만들고 정답 문장이 있는 25세트만 사용), 증강은 실제 기록 1개에서 파생

정답 문장
280개 중 210개 사용
70세트 x 4말투, 단순 나열 제외

학습 / 검증 분할
168 / 42
80 : 20, 학습 한 바퀴마다 검증, 레코드 단위 무작위 분할

결과 예시

뇌파 6지표가 요약 문장이 됩니다

입력 형식 (뇌파 지표 값)

스트레스	0.19
몰입	0.77
이완	0.76
흥분	0.48
흥미	0.81
집중	0.66

생성 예시 (일부 발췌)

"두 번째 단계에서는 스트레스가 매우 낮고 이완이 매우 높은 수준으로 상승하며 감정과 생체 지표 사이의 초기 대비가 형성됩니다."

Llama 3.1 8B (LoRA) 생성 문장 · 출처: Generated_Report.txt
입력 형식과 생성 예시를 각각 보여 주는 카드입니다

뇌파 6지표를 입력하면 모델이 요약 문장을 생성. 생성 문장은 일부 발췌(Llama 3.1 8B LoRA, 저장소 Generated_Report.txt). 이 입력은 학습 데이터에도 포함되어 있음(한계 참고)

구조



사례

CASE 01

규칙 문장·범용 LLM 대신 추가학습 선택

P 문제 뇌파 지표는 숫자라 상담자가 바로 읽기 어렵습니다. 협력 기업과 정해진 형식의 서술형 문장으로 풀어 주기로 합의했습니다.

서술형 문장을 만드는 방법 비교

	규칙으로 만든 문장	범용 LLM	경량 추가학습 선택
표현	반복되고 지표를 하나씩만 해석	뇌파 분야 표현이 부족하고 일반론에 그침	정해진 형식과 표현을 학습
데이터	필요 없음	필요 없음	100개 이하라 규칙 증강과 여러 말투의 정답으로 보완
판단	제외	제외	선택

A 실행
- 4비트 양자화와 LoRA(대상 q_proj·v_proj)로 개인 GPU(RTX 4070 Ti)에서 학습
- 학습 바퀴 수를 10에서 7로 줄임(커밋 기록, 비교 수치는 없음)

R 결과 체험 시작·중간·마지막 3단계를 각각 한 문장으로 서술하는 모델을 만들었습니다. 정량 평가 없이 생성 문장을 직접 읽어 확인했습니다.

CASE 02

규칙 증강으로 학습 세트를 늘리고 한계까지 확인

P 문제 학생 기록이 적어 그대로는 학습이 어려워, 규칙에 따라 가상 기록을 만들어 늘렸습니다.

50세트	25세트	45세트	1개
규칙으로 생성한 증강 세트	정답 문장이 있어 학습에 쓴 증강 세트	학습에 쓴 실제 기록 세트 (70세트 중 약 64%)	증강의 원본이 된 실제 기록

A 분석
- 무작위 생성은 스트레스·이완이 함께 오르는 비현실 조합이 나와 제외

A 실행
- 처음 9세트는 원본 값의 ±20%, 나머지는 이완 기준값을 0.1~0.9에서 뽑고 스트레스를 그 반대로 맞춤(집중·흥미·관여는 공통 기준값에 ±20%)
- 감정 색·채움 정도는 정해진 단어표에서 선택, 무작위 값 고정, 값 이름 표기를 원본 기준으로 통일

R 결과
50세트를 만들었지만 정답 문장이 있는 25세트만 학습에 쓰였고, 모두 실제 기록 1개에서 파생됩니다. 실제 분포와의 유사도는 검증하지 못했습니다.

한계

- 정량 평가 없음, 품질은 생성 문장을 직접 읽어 확인한 수준
- 검증 분할이 레코드 단위 무작위라, 같은 입력의 3말투 정답이 학습·검증에 나뉨(고유 입력 70개), 검증 손실은 독립 검증이 아님
- 결과 카드의 입력도 학습 입력과 같은 문자열이라, 생성 결과가 처음 보는 입력에 대한 것은 아님
- 증강은 실제 기록 1개에서만 파생되고 실제 분포와의 유사도 미검증, 문장 시작 표현을 고정해 문장 다양성도 제한적
- 일부 감정 단어에 대응시킨 값은 협력 기업 기준과 맞는지 확인 필요

Witches-Chat-Core 팀 완료

근거 조항과 함께 답하는 온프레미스 규정 RAG 챗봇

경북대 학사 규정은 한글(HWP)·워드(DOCX)·PDF로 흩어져 있고, 클라우드 AI에는 규정과 개인정보를 보내기 어렵습니다. 학교 안에서 규정을 검색해 근거와 함께 답하는 챗봇을 팀으로 만들었고, 저는 앞단인 규정 문서를 Markdown으로 바꾸고 조·항 구조를 표시하는 일을 맡았습니다.

기간 2026.03 ~ 2026.06

역할 팀 프로젝트(5명) · 규정 문서 Markdown 변환 담당

기술 Python · PyMuPDF · python-docx · rhwp-python · Open WebUI · Ollama · ChromaDB

저장소 비공개 저장소

제가 맡은 일

- HWP·DOCX·PDF 규정을 Markdown으로 변환하는 형식별 변환기
- 편·장·절·조·항·호·목을 Markdown 기호로 표시
- 제어문자·서식 노이즈 제거, 표와 양식을 본문에서 분리
- DOCX·PDF 변환 속도 개선, 변환 전후 글자 수 점검 로그
- 오피스·이미지·음성 변환 추가, 문서 쪼개기에 쓸 구간 정보를 본문에 표시해 전달

팀원 담당·팀 공통

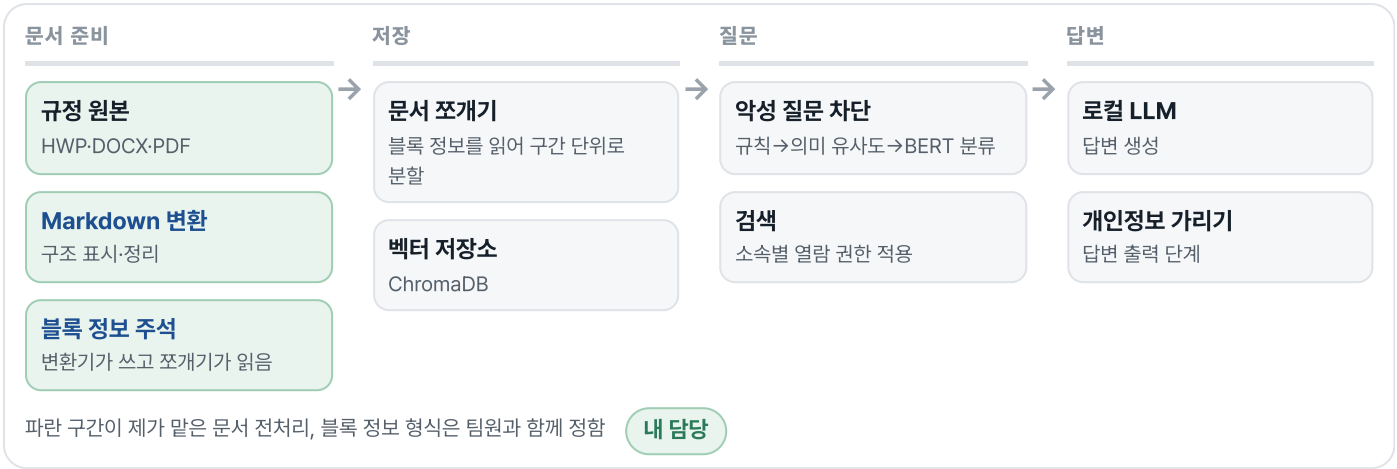
문서 쪼개기, 벡터 변환, 소속별 검색, 악성 질문 차단, 답변 속 개인정보 가리기, 채팅 화면 연동, 서버 구성은 팀원 담당. 구간 정보 형식은 팀원과 함께 정함.

정리된 규정 문서
Markdown 28개
서로 다른 규정 24종, 원본 29개 파일(HWP 20·DOCX 5·PDF 4)에서 변환, 같은 규정이 여러 형식이면 각각 변환

PDF 변환 시간(참고)
약 70초 → 15초
커밋 메시지 기록, 측정 환경 기록 없음
운영 기록

팀 악성 질문 차단율
98.46%
악성 입력 130개 중 128개 차단(평가 입력 210개 중, 논문 기준), 팀 전체 결과
팀 측정

구조



파란 구간이 제가 맡은 문서 전처리, 블록 정보 형식은 팀원과 함께 정함 **내 담당**

사례

CASE 01

HWP·DOCX·PDF를 Markdown 하나로 통일

P 문제 규정이 세 가지 파일 형식으로 섞여 있고, 조·항·호 계층이 의미를 정합니다. 형식별로 다루면 문서 쪼개기와 검색도 형식마다 따로 만들어야 합니다.

A 분석
- 형식별 문서 쪼개기는 팀원이 형식마다 따로 처리해야 해 제외
- Markdown은 문서 쪼개기의 표준 입력이고 제목·목록·표를 표현할 수 있어 팀원 모두 같은 입력으로 사용 가능

A 실행
- 형식별 변환기를 두되 결과 구조는 동일하게, 처음에는 HWP를 DOCX로 수동 변환하고 이후 직접 변환 추가
- 큰 규정집은 DOCX·PDF 라이브러리 처리가 느려 XML·블록을 직접 읽는 방식으로 바꿈

R 결과 원본 29개 파일에서 Markdown 28개(규정 24종)를 만들어 문서 쪼개기 단계에 전달했습니다. 변환 속도는 PDF 기준 약 70초에서 15초로 줄었다고 커밋에 적었지만 측정 환경 기록은 없는 참고 수치입니다.

CASE 02

표와 신청서 양식을 구분해 본문에서 분리

P 문제 신청서 서식과 빈 칸 많은 표가 본문에 섞이면 검색 결과에 불필요한 내용이 끼고 문서 쪼개기도 어렵습니다.

표 처리 방식 비교

	모든 표를 같은 방식으로	표 모양·양식 표현으로 판별 **선택**
내용 표와 양식	구분할 수 없음	구분해 양식만 따로 변환
검색 결과	신청서 서식이 본문에 섞임	규정 본문과 분리
판별 근거	없음	빈 칸이 있는 여러 열 표, 양식 표현(예·아니오 등), 정해 둔 글자 패턴

R 결과 양식 표가 본문과 분리되어 문서 쪼개기 단계로 전달됩니다. 판별 정확도는 측정하지 못했습니다.

한계

- 전처리 구간에는 자동 테스트가 없고, 변환 결과는 글자 수 대조 로그(85% 미만이면 경고, 중단은 안 함)와 눈으로 확인
- 구조 표시와 표·양식 판별의 정확도를 정답과 대조해 측정하지 않았음
- 팀 악성 질문 차단 결과는 직접 만든 입력 210개(악성 130개 포함) 기준이고 실제 질의 평가가 아님. 챗봇 전체의 답변 정확도·근거 일치 수치는 없음
- 변환·점검은 24종 규정, 소량 문서로 확인해 속도 개선의 체감 근거가 약함. 이미지 변환은 OCR 설치 후 검증 필요

Port Entity Matching

개인 완료

입출항 기록을 표준 선박 한 척으로 잇는 매칭 파이프라인

해양수산부 주최 DACON 항만 문제 해결 AI 대회에 개인으로 참가해, 비공개 리더보드 468명 중 106위(0.91989)로 마쳤습니다. 과제는 오타·한글 표기·빈 제원이 섞인 입출항 기록 한 줄을 약 7만 8천 척의 표준 선박 중 하나로 연결하는 것입니다. 한글 선박명이 점수의 70%라 한글 매칭에 집중했고, 발음 코드와 LLM 후보로 시작해 선박 카탈로그의 영문명을 한글로 바꿔 대조하는 역방향 채널까지 넣었습니다.

기간 2026.10 ~ 2026.11

역할 대회 개인 참가, 후보 검색·순위 모델·평가 도구 단독 구현

기술 Python · LightGBM · RapidFuzz · scikit-learn · PyTorch · Kanana 1.5 2.1B · Midm 2.0 Mini · pytest · uv

저장소 github.com/KTHYEONG/port-entity-matching

비공개 리더보드 최종	공개 리더보드 점수	이름 변형 시험 점수	내부 검증 점수
0.91989	**0.8805 → 0.9595**	**0.8162 → 0.9477**	**0.9910**
468명 중 106위, 테스트 100% 기준 최종 순위. 공개 0.9595에서 약 0.04 낮아졌고 원인은 분석하지 못했음	테스트 50% 기준, 규칙 기반 대비 최종 제출물 (한글 507/532)	단어 순서 바꾸기·빼기 등 20가지 변형, 내 컴퓨터 모의 기준	최종 채택 설정, 선박 단위 5분할 검증, LLM 후보 추가 전 모델이며 현재 코드의 값은 미측정. 사례 1의 0.9875는 더 이른 v2 모델의 값
운영 기록	운영 기록	백테스트	백테스트

구조



후보를 모은 뒤 랭커가 한 척을 고르는 구조(한글 행과 비한글 행의 경로가 다르고, 학습 보강은 학습 시점에만 적용)

사례

CASE 01

한글 선박명, 발음 코드·LLM 후보·역방향 채널로 분담

P 문제 한글 이름은 영어 외래어, 한국어 로마자, 약어 읽기가 섞여 규칙 하나로 못 맞춥니다. 한글 행은 데이터의 약 9.7%, 점수의 70%입니다.

1단계	공개 0.8805: 규칙 기반 기준선
2단계	0.9163: LLM 영문 표기 후보 추가
3단계	**0.9525: 역방향 채널·합성 영문 행 추가(한글 505/532)**
4단계	0.9563: 비한글 후보 폭 확대
5단계	**0.9595: 최종 제출물(한글 507/532), 비공개 최종 0.91989**

한글 선박명 유형 (한글 → 정답 표기)

리플렉션	→	**Reflection**	영어 외래어
흥아	→	**Heung-A**	한국어 로마자
에스티아이	→	**STI**	약어 읽기

A 분석

- 표준 영문 변환만 쓰면 한글 오류가 24건에서 63건으로 늘어 제외, 발음 코드(자음·모음 소리 기호 + 외래어 보정)는 23건에서 14건(5회 학습 평균)
- 처음 보는 표기에 약해 LLM 영문 표기 후보를 추가, 역방향 채널은 당시 최고 모델의 한글 오류 41건 중 17건을 해소할 수 있음을 확인
- 세 번째 한글 표기 생성, 합성 한글 행, 재순위 가중치 상향은 한글 정답 500~504에 머물러 제외

A 실행

- 발음 코드 + 톤수 범위 후보에 LLM 후보를 합산하고, LLM은 후보만 늘리며 최종 판단은 순위 모델, 한글 상위 10개는 LLM 가능성 점수로 재정렬
- 카탈로그 영문명을 두 LLM(Midm, Kanana)으로 미리 한글 변환해 두고, 한글 행은 자모 상위 20척을 후보에 합산하고 특징 3개 추가
- 학습에만 쓰는 변형 6종(이름 잘림, 표기 변형, 톤수 오류, 한글 자모 잡음 등)과 카탈로그 기반 합성 영문 행 15,000개

R 결과

공개 점수가 0.8805에서 0.9595로 올랐습니다. 재학습 오차가 한글 ±2행, 비한글 ±4행이라 한글 3행 이상 개선만 인정했습니다. 단계별 값은 리더보드에서 확인한 공개(테스트 50%) 점수입니다. 운영 기록

CASE 02

오르지 않는 지점에서 멈추고, 남은 한글 오류 25건의 원인 구분

P 문제 역방향 채널 뒤에도 한글 오류 25건이 남았습니다. 표기를 더 정확히 만들거나 모델을 키우면 줄어드는지 모른 채 시도만 늘리면 제출 횟수만 쓰게 됩니다.

A 분석

- 더 큰 LLM으로 카탈로그 표기를 다시 만들어 정확도가 62%에서 77%까지 올라도 점수는 그대로였고, 다른 랭커·선박 사전확률·검색 확대도 효과가 없거나 하락(아래 표)
- 남은 오류는 이름이 거의 같은 자매선 중 어느 배인지 한 행만으로 정할 수 없는 경우가 대부분
- 같은 호출부호의 다른 기록을 모아 투표하면 한글 오류가 줄어들지만(합성 쌍둥이 평가에서 100건 → 6건, 실제 학습 데이터에서 21건 → 19건), 다른 행을 쓰는 방식이라 대회 규칙상 제외

A 실행

- 표기·모델·랭커 확대 시도는 중단하고 미채택으로 기록
- 학습 선박만 답하는 제출로 정답이 0임을 확인한 뒤, 호출부호 일치 없이 1위가 학습 선박이면 다음 학습 밖 후보로 교체 (대회 분할 구조를 이용한 규칙임을 문서에 명시)
- 비한글 행의 후보 폭 확대와 학습 데이터의 단어 대응표·약어 읽기로 만든 표기 추가

R 결과 한글 정답이 505에서 507로, 점수가 0.9525에서 0.9595로 올랐습니다(후보 폭 확대 0.9563, 학습 선박 제외 0.9581). 이후 시도는 모두 효과가 없었습니다. 운영 기록

리더보드로 확인한 시도 (한글 정답 수 변화)

더 큰 LLM 표기	→	**0 ~ −1**	표기 정확도 62→77%
CatBoost 랭커	→	**−3**	랭커 종류는 병목 아님
선박 사전확률	→	**−4**	비한글도 13행 하락
검색·재순위 확대	→	**0**	후보 범위는 병목 아님

한계

- 공개 0.9595가 비공개 0.91989로 약 0.04 낮아진 원인과 내부 검증–리더보드 차이를 끝까지 설명하지 못함, 내 컴퓨터의 모의 오류로는 리더보드의 한글 오류가 재현되지 않음
- 점수 개선 여부를 공개 리더보드(테스트 50%)로 반복 확인했고, 비공개 하락과의 관계는 확인하지 못함. 정답 집합을 추정하는 분석 도구(evaluation/lb)는 개발 전용으로 제출 코드에서 쓰지 않음
- 규칙 해석 위험: 역방향 채널(카탈로그 이름을 미리 한글로 변환)은 허용 여부를 운영진에게 직접 확인받지 못했고(공식 답변은 학습 데이터 기반 LLM 증강까지, 생성 코드·프롬프트는 보관), 학습 선박 제외는 대회 분할 구조를 이용한 규칙으로 현장에서는 호출부호 기억이 그 역할
- 서버(L4)에서 실측하지 않아 추론 시간 약 16분은 로컬 측정에서 낸 추정치
- 단어 하나 빠진 이름은 약함(영문 약 0.69, 한글 약 0.65, 모의 기준), 이름·톤수가 같은 자매선은 한 행만으로 구분 어려움
- 대회 데이터 재배포 금지로 저장소만으로는 학습·평가 재현 불가

기술 · 기타

사용한 기술

Python · Llama 3.1 8B · Transformers · TRL · PEFT(LoRA) · bitsandbytes · pandas · numpy · PyMuPDF · python-docx · rhwp-python · Open WebUI · Ollama · ChromaDB · LightGBM · RapidFuzz · scikit-learn · PyTorch

AI 활용

AI 코딩 도구를 주로 코드를 쓰는 데 사용했고, 아이디어를 다듬거나 처음 접하는 분야를 공부할 때도 썼습니다. 수치와 동작은 직접 확인했고, 확인하지 못한 것은 성과로 쓰지 않았습니다.

AI에 맡긴 일	직접 한 일
코드 작성	결과 수치와 동작을 직접 확인
아이디어 정리와 도메인 학습 보조	확인하지 못한 내용은 성과로 쓰지 않기

수치 기준 표기

백테스트 과거 데이터 시뮬레이션 **재현 시뮬레이션** 체결·증거금 규칙을 적용한 원장 리플레이 **평가셋 측정** 정해진 평가 데이터로 잰 값
팀 측정 팀 전체 측정값(제 기여분만의 값이 아님) **운영 기록** 실제로 돌린 기록

그 밖의 프로젝트

auto-mobility 실내 공간을 3D 모델로 복원하고 센서 데이터로 검증하는 온라인 현장실습 팀 프로젝트(3명). 저는 Visual SLAM 비교와 평가를 주로 맡았습니다.

K-Stock Engine 국내주식 다중 팩터 전략을 연구하고 가상 장부로 기록합니다. 아직 불완전한 단계라 성과는 싣지 않았습니다.

연락

xogud3624@gmail.com · github.com/KTHYEONG · kthyeong.github.io