AI · LLM 데이터 포트폴리오

김태형

TaeHyeong Kim

모델이 배우는 문장과 검색할 문서를 직접 설계했습니다

경북대학교 컴퓨터학부 · 2027.02 졸업 예정
xogud3624@gmail.com · github.com/KTHYEONG · kthyeong.github.io

모델 앞단의 데이터를 맡았습니다. Emori(팀)는 상담 문장 모델의 학습 데이터, Witches(팀)는 학사 규정 검색용 문서 구조화, Port Entity Matching(개인)은 한글 선박명 매칭입니다. 팀 프로젝트는 제 담당과 팀 전체 결과를 나눠 적었습니다.

프로젝트

01 **Emori** 팀 완료

뇌파·감정을 상담 문장으로 바꾸는 모델의 학습 데이터와 파인튜닝

50세트
규칙으로 늘린 학습 데이터

210개
정답 문장 (280개 중 사용)

168 / 42
학습 / 검증 분할

02 **Witches-Chat-Core** 팀 완료

학사 규정을 검색용 Markdown으로 구조화한 RAG 전처리

3형식 → Markdown
HWP·DOCX·PDF 규정을 하나로 통일

조·항·호 구조 표시
계층을 기호로 남겨 문서 쪼개기에 전달

표·양식 분리
본문과 구분해서 전달

98.46%
악성 질문 차단 (팀 전체, 130개 중 128개)

03 **Port Entity Matching** 개인 진행 중

규칙으로 못 푸는 한글 선박명을 LLM 후보로 보완한 대회

0.8805 → 0.9558
공개 리더보드 점수 (진행 중)

17 / 41건
역방향 채널로 해소 확인한 한글 오류

> **수치를 읽는 법**
>
> 모든 수치에 측정 방식을 표시했습니다. 실계좌 수익과 수상(Emori 팀 논문 제외)은 싣지 않았습니다. 진행 중인 대회의 점수와 순위는 확인한 시점의 값입니다. 근거는 각 저장소 README에 있습니다.

Emori 팀 완료

뇌파·상담 텍스트 멀티모달 AI, 뇌파 요약 LLM 담당

VR 체험 중 뇌파와 상담 인터뷰 텍스트를 함께 분석해 상담자가 학생 상태를 빠르게 파악하도록 돕는 산학협력 프로젝트입니다(협력기관 (주) 모티버). 저는 수치 뇌파 지표를 서술형 리포트로 바꾸는 부분을 맡아, 100개 이하의 데이터를 규칙으로 늘리고 Llama 3.1 8B를 경량 추가학습 방식으로 파인튜닝했습니다.

기간	2025.09 ~ 2025.12
역할	뇌파 전처리, 학습 데이터 구축, Llama 3.1 8B 경량 추가학습(LoRA) (팀 프로젝트)
수상	2025 한국정보기술학회 추계종합학술대회 우수논문상(동상) · 팀 논문
기술	Python Llama 3.1 8B Transformers TRL PEFT(LoRA) bitsandbytes pandas numpy
저장소	github.com/KTHYEONG/Emori

제가 맡은 일

- 뇌파·VR 결과 텍스트 파일을 하나의 JSON으로 통합, 값과 이름 정리
- 규칙 기반 데이터 증강 50세트
- 정답 문장 4가지 말투 작성 (70세트 x 4말투 = 280개)
- Llama 3.1 8B 경량 추가학습과 서술형 요약 생성

팀원 담당·팀 공통

상담 인터뷰 텍스트의 감정 키워드 추출(단어 분석과 문맥 이해 언어모델 결합), 키워드와 감정의 연관 분석, 통합 화면은 팀원이 맡았습니다. 제 성과로 주장하지 않습니다.

증강 학습 데이터

50세트

규칙으로 생성, 감정·강도 값은 모두 정해진 단어표 안의 값

정답 문장

280개 중 210개 사용

70세트 x 4말투, 단순 나열 제외

학습 / 검증 분할

168 / 42

80 : 20, 학습 한 바퀴마다 검증

결과 예시

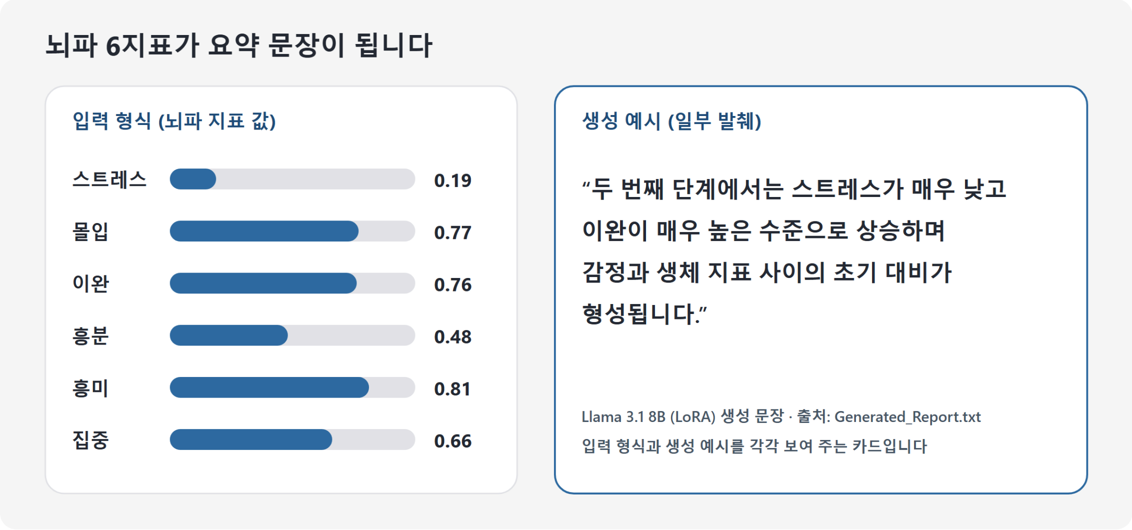

"두 번째 단계에서는 스트레스가 매우 낮고 이완이 매우 높은 수준으로 상승하며 감정과 생체 지표 사이의 초기 대비가 형성됩니다."

Llama 3.1 8B (LoRA) 생성 문장 · 출처: Generated_Report.txt

입력 형식과 생성 예시를 각각 보여 주는 카드입니다

뇌파 6지표를 입력하면 모델이 요약 문장을 생성. 생성 문장은 일부 발췌(Llama 3.1 8B LoRA, 저장소 Generated_Report.txt)

구조

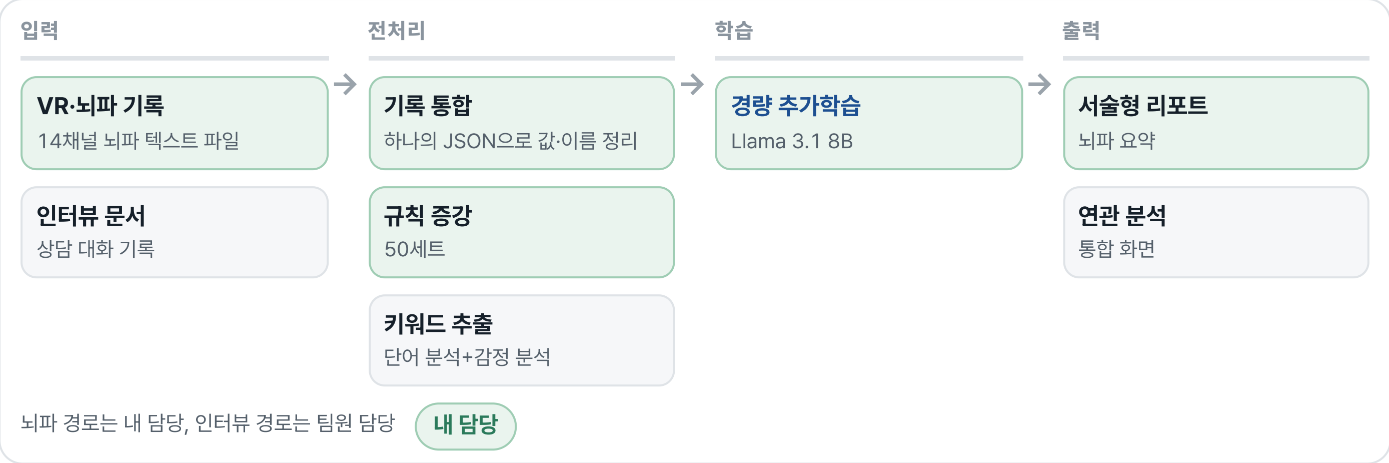

입력

VR·뇌파 기록
14채널 뇌파 텍스트 파일

인터뷰 문서
상담 대화 기록

전처리

기록 통합
하나의 JSON으로 값·이름 정리

규칙 증강
50세트

키워드 추출
단어 분석+감정 분석

학습

경량 추가학습
Llama 3.1 8B

출력

서술형 리포트
뇌파 요약

연관 분석
통합 화면

뇌파 경로는 내 담당, 인터뷰 경로는 팀원 담당 **내 담당**

사례

CASE 01

규칙 문장·범용 LLM 대신 추가학습 선택

기록 통합
뇌파·VR 파일을 JSON으로

데이터 늘리기
규칙으로 50세트

정답 작성
4가지 말투 280개

추가학습
Llama 3.1 8B

리포트
서술형 요약 생성

P 문제
뇌파 지표는 숫자라 상담자가 바로 읽기 어렵습니다. 협력 기업과 정해진 형식의 서술형 문장으로 풀어 주기로 합의했습니다.

A 분석
- 규칙으로 만든 문장: 표현이 반복되고 지표를 하나씩만 해석해 제외
- 범용 LLM: 뇌파 분야 표현이 부족하고 일반론에 그쳐 제외
- 데이터 100개 이하: 파인튜닝 + 데이터 늘리기 + 여러 말투의 정답

A 실행
- 모델을 4비트로 줄여 적은 GPU 메모리로 학습
- 모델 일부 층에만 작은 추가 가중치를 붙여 학습(크기 32, 반영 비율 16)
- 학습 7바퀴, 1건씩 8건 모아 갱신, 학습 속도 3e-4, 개인용 GPU(RTX 4070 Ti)
- 기록 변환부터 요약 생성까지 한 흐름으로 실행

R 결과
체험 시작·중간·마지막 3단계를 각각 한 문장으로 서술. 정량 평가 없이 생성 문장을 직접 읽어 확인.

CASE 02

비현실적 조합을 막는 데이터 생성 규칙 설계

P 문제	학생 기록이 적어 그대로는 학습이 어려워, 규칙에 따라 가상 기록을 만들어 늘려야 했습니다.
A 분석	• 무작위 생성: 스트레스·이완이 함께 오르는 등 비현실 조합이 나와 제외 • 감정 이론(러셀 모형) 등을 참고해 지표 간 관계를 규칙으로 정리
A 실행	• 처음 9세트: 제공 기록의 흐름 유지 • 나머지: 원본 값의 위아래 20% 범위에서 생성 • 스트레스는 이완과 반대로 움직이게 하고 극단 조합은 드물게 제한 • 무작위 값 고정, 값 이름 표기를 원본 기준으로 통일한 뒤 다시 생성
R 결과	50세트 생성, 감정·강도 값이 모두 정해진 단어표 안의 값임을 확인. 실제 데이터와의 유사도는 미검증.

한계

- 정량 평가 없음, 품질은 생성 문장을 직접 읽어 확인한 수준
- 가상 기록과 실제 기록을 섞어 사용, 실제 분포와의 유사도 미검증
- 일부 감정 단어에 대응시킨 값은 협력 기업 기준과 맞는지 확인 필요

Witches-Chat-Core 팀 완료

근거 조항과 함께 답하는 온프레미스 규정 RAG 챗봇

경북대 학사 규정은 한글(HWP)·워드(DOCX)·PDF로 흩어져 있고, 클라우드 AI에는 규정과 개인정보를 보내기 어렵습니다. 학교 안에서 규정을 검색해 근거와 함께 답하는 챗봇을 팀으로 만들었고, 저는 앞단인 규정 문서를 Markdown으로 바꾸고 조·항 구조를 표시하는 일을 맡았습니다.

기간	2026.03 ~ 2026.06
역할	팀 프로젝트(5명) · 규정 문서 Markdown 변환 담당
기술	Python PyMuPDF python-docx rhwp-python Open WebUI Ollama ChromaDB
저장소	비공개 저장소

제가 맡은 일

- HWP·DOCX·PDF 규정을 Markdown으로 변환하는 형식별 변환기
- 편·장·절·조·항·호·목을 Markdown 기호로 표시
- 제어문자·서식 노이즈 제거, 표와 양식을 본문에서 분리
- DOCX·PDF 변환 속도 개선, 변환 전후 글자 수 점검 로그
- 오피스·이미지·음성 변환 추가, 문서 쪼개기에 쓸 구간 정보를 본문에 표시해 전달

팀원 담당·팀 공통

문서 쪼개기, 벡터 변환, 소속별 검색, 악성 질문 차단, 답변 속 개인정보 가리기, 채팅 화면 연동, 서버 구성은 팀원 담당. 구간 정보 형식은 팀원과 함께 정함.

정리된 규정 문서

Markdown 28개

HWP 20·DOCX 5·PDF 4개에서 변환(중복 형식 포함)

PDF 변환 시간(참고)

약 70초 → 15초

커밋 메시지 기록, 측정 환경 기록 없음

운영 기록

팀 악성 질문 차단율

98.46%

직접 만든 악성 입력 130개 중 128개 차단(논문 기준), 팀 전체 결과

팀 측정

구조

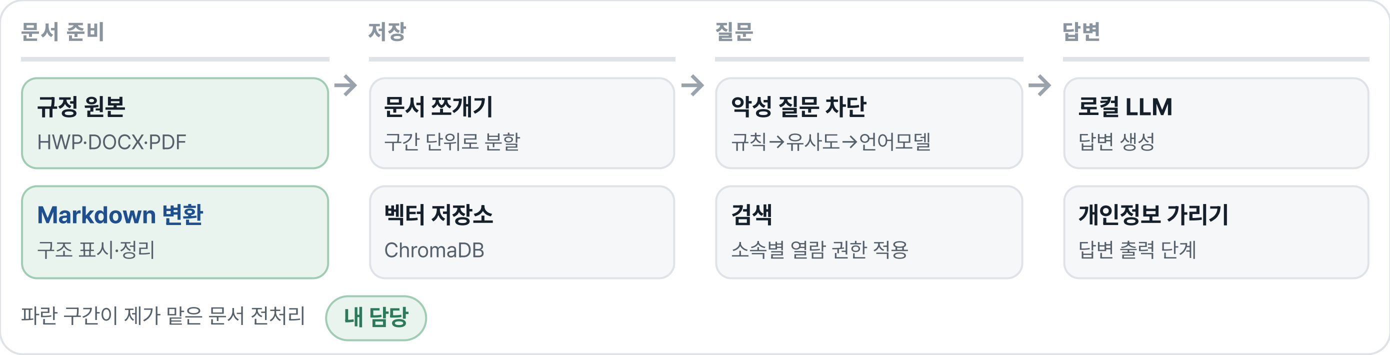

문서 준비

규정 원본
HWP·DOCX·PDF

Markdown 변환
구조 표시·정리

저장

문서 쪼개기
구간 단위로 분할

벡터 저장소
ChromaDB

질문

악성 질문 차단
규칙→유사도→언어모델

검색
소속별 열람 권한 적용

답변

로컬 LLM
답변 생성

개인정보 가리기
답변 출력 단계

파란 구간이 제가 맡은 문서 전처리 내 담당

사례

CASE 01

HWP·DOCX·PDF를 Markdown 하나로 통일

규정 원본	형식별 변환	구조 표시	잡음 정리	쪼개기 전달
HWP·DOCX·PDF	형식마다 변환기	조·항·호 기호	깨진 문자 제거·표 분리	구간 정보 포함

P **문제**

규정이 세 가지 파일 형식으로 섞여 있고, 조·항·호 계층이 의미를 정합니다. 형식별로 다루면 문서 쪼개기와 검색도 형식마다 따로 만들어야 합니다.

A **분석**

- 형식별 문서 쪼개기: 팀원이 형식마다 따로 처리해야 해 제외
- Markdown: 문서 쪼개기의 표준 입력, 제목·목록·표 표현 가능
- 팀원 모두 같은 입력 형식 사용 가능

A **실행**

- 형식별 변환기를 두되 결과 구조는 동일하게
- 초기에는 HWP를 DOCX로 수동 변환
- 이후 HWP 직접 변환 추가

R **결과**

원본 HWP 20·DOCX 5·PDF 4개를 Markdown 28개로 정리해 문서 쪼개기 단계에 전달.

원본 형식과 변환 결과 개

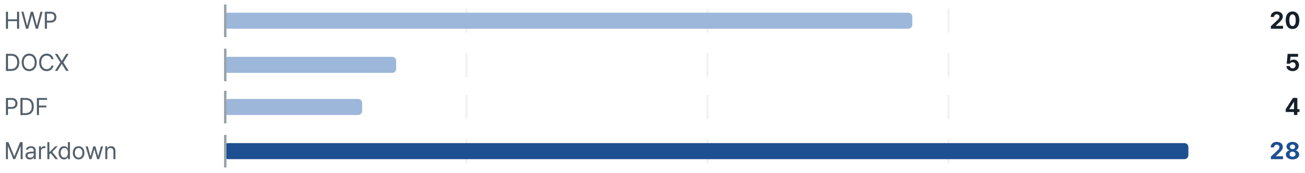

형식별 원본 파일 수와 Markdown 변환 결과

CASE 02

표와 신청서 양식을 구분해 본문에서 분리

P **문제**

신청서 서식과 빈 칸 많은 표가 본문에 섞이면 검색 결과에 불필요한 내용이 끼고 문서 쪼개기도 어렵습니다.

A **분석**

- 표 일괄 처리: 내용 표와 양식 구분 불가, 제외
- 빈 칸 비율 등 표 모양과 양식 표현으로 판별

A **실행**

- 빈 칸 많은 여러 열 표, 양식 표현(예/아니오), 정해 둔 글자 패턴이면 양식으로 판별
- 양식은 본문과 따로 변환
- 표를 따로 벡터로 변환해 저장 가능

R **결과**

양식 표가 본문과 분리되어 문서 쪼개기 단계로 전달. 판별 정확도는 미측정.

한계

- 전처리 구간 자동 테스트 없음, 변환 전후 글자 수 비교 로그(85% 미만이면 경고)와 눈으로 확인
- 팀 악성 질문 차단 결과는 직접 만든 입력 210개 기준, 실제 질의 평가 아님
- 이미지 변환은 글자 인식(OCR) 도구 설치 후 검증 필요

Port Entity Matching

개인

진행 중

입출항 기록을 표준 선박 한 척으로 잇는 매칭 파이프라인

DACON 항만 문제 해결 AI 대회 과제입니다. 오타·한글 표기·빈 제원이 섞인 입출항 기록 한 줄을 약 7만 8천 척의 표준 선박 중 하나로 연결합니다. 한글 선박명이 점수의 70%라 한글 매칭에 집중했습니다. 발음 코드와 LLM 후보로 시작해, 선박 카탈로그의 영문명을 한글로 바꿔 대조하는 역방향 채널까지 넣었습니다.

기간	2026.10 ~ 진행 중
역할	대회 개인 참가, 후보 검색·순위 모델·평가 도구 단독 구현
기술	Python LightGBM RapidFuzz scikit-learn PyTorch Kanana 1.5 2.1B pytest uv
저장소	비공개 저장소

내부 검증 점수

0.9910

선박 단위 5분할 검증, LLM 후보 추가 전 모델

백테스트

이름 변형 시험 점수

0.8162 → 0.9477

단어 순서 바꾸기·빼기 등 20가지 변형, 내 컴퓨터 모의 기준

백테스트

공개 리더보드 점수

0.8805 → 0.9558

규칙 기반 방식 대비 현재 최고점, 진행 중 110위 (본인 확인)

운영 기록

구조

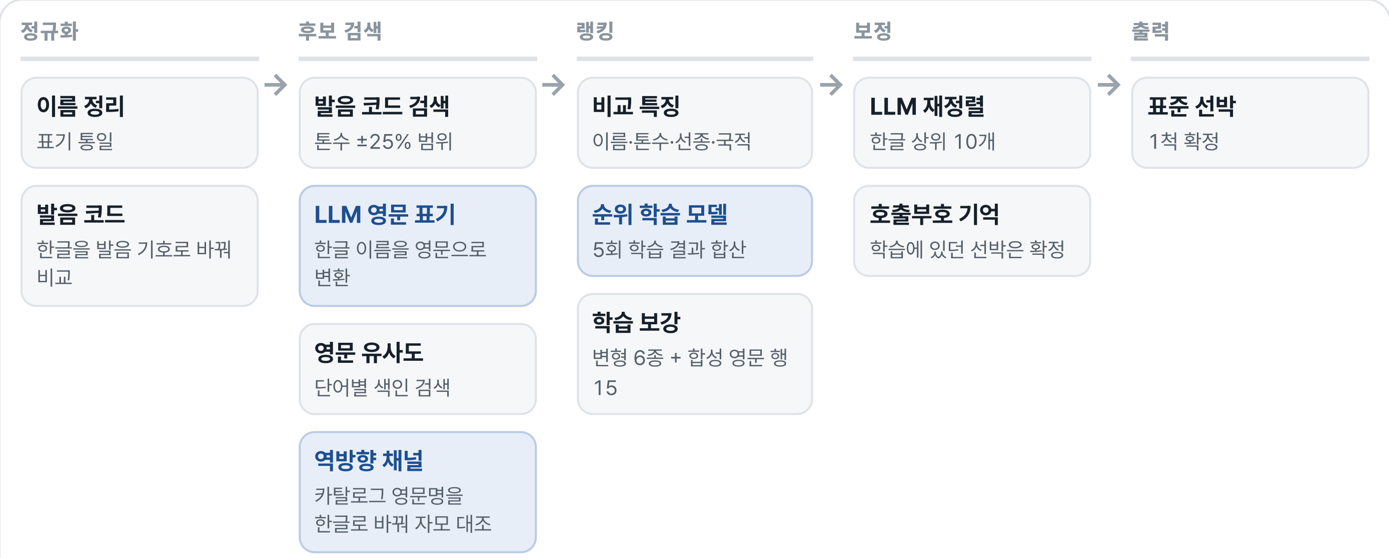

정규화

이름 정리
표기 통일

발음 코드
한글을 발음 기호로 바꿔 비교

후보 검색

발음 코드 검색
톤수 ±25% 범위

LLM 영문 표기
한글 이름을 영문으로 변환

영문 유사도
단어별 색인 검색

역방향 채널
카탈로그 영문명을 한글로 바꿔 자모 대조

랭킹

비교 특징
이름·톤수·선종·국적

순위 학습 모델
5회 학습 결과 합산

학습 보강
변형 6종 + 합성 영문 행 15

보정

LLM 재정렬
한글 상위 10개

호출부호 기억
학습에 있던 선박은 확정

출력

표준 선박
1척 확정

후보를 모은 뒤 랭커가 한 척을 고르는 구조

사례

CASE 01

한글 선박명, 발음 코드·LLM 후보·역방향 채널로 분담

정규화 이름 정리
후보 검색 발음 코드 + 톤수 범위
LLM 표기 영문 후보 추가
역방향 채널 영문명→한글 변환 대조
순위 모델 후보별 순위 학습
재정렬 한글 상위 10개
선박 1척 표준 선박 확정

P 문제 한글 이름은 영어 외래어, 한국어 로마자, 약어 읽기가 섞여 규칙 하나로 못 맞춥니다. 한글 행은 데이터의 약 9.7%, 점수의 70%입니다.

A 분석

- 표준 영문 변환만 사용: 한글 오류 24건에서 63건, 제외
- 발음 코드 채택: 한글을 자음·모음 소리 기호로 바꿔 비교 + 외래어 보정(발음 안 나는 R, 첫 글자 H, 모음 Y)
- 한글 오류 23건에서 14건 (5회 학습 평균)
- 처음 보는 표기에 약해 LLM 영문 표기 후보 추가
- 역방향 채널: 카탈로그 영문명을 LLM이 한글로 바꿔 자모로 대조, 당시 최고 모델의 한글 오류 41건 중 17건 해소 가능 확인
- 제외: 세 번째 한글 표기 생성(한글 정답 504), 합성 한글 행(501), 재순위 가중치 상향(500~502)

A 실행

- 발음 코드 + 톤수 ±25% 후보에 LLM 후보 합산
- LLM은 후보만 늘리고, 최종 판단은 순위 모델
- 한글 상위 10개를 LLM 가능성 점수로 재정렬
- 카탈로그 영문명을 두 LLM(Midm, Kanana)으로 한글 변환해 두고, 한글 행은 자모 상위 20척을 후보에 합산, 특징 3개 추가
- 학습에만 쓰는 변형 6종(이름 잘림, 표기 변형, 톤수 오류, 한글 자모 잡음 등)과 카탈로그 기반 합성 영문 행 15,000개

R 결과 리더보드 0.8805(규칙 기반) → 0.9163(LLM 후보) → 0.9525(역방향 채널·합성 행, 한글 505/532, 비한글 1713/1784) → 현재 최고 0.9558. 재학습 오차가 한글 ±2행, 비한글 ±4행이라 한글 3행 이상 개선만 인정했습니다. 운영 기록

한글 선박명 유형 (한글 → 정답 표기)

리플렉션	→	**Reflection**	영어 외래어
흥아	→	**Heung-A**	한국어 로마자
에스티아이	→	**STI**	약어 읽기

공개 리더보드 점수 점수 운영 기록

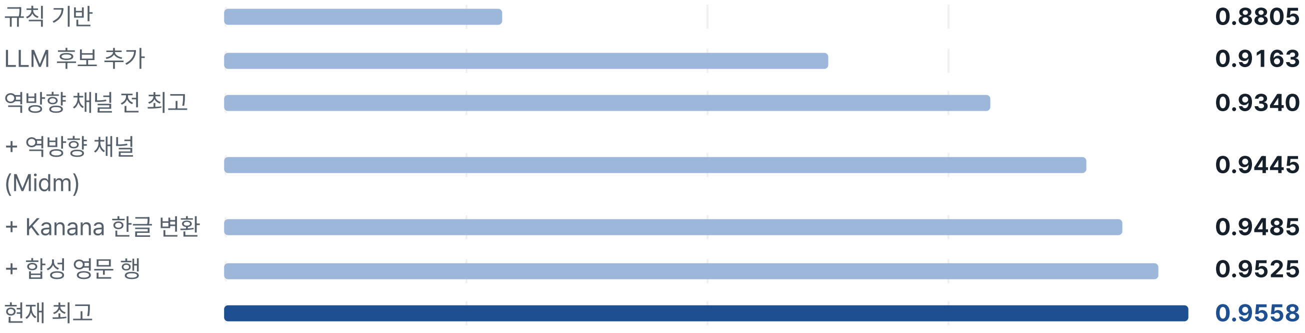

점수는 한글 0.7, 비한글 0.3 가중. 단계별 값은 정답 행 수에서 환산, 마지막은 제출 화면 값 (막대 시작값 0.85)

한계

- 0.9910은 LLM 후보 추가 전 값, 현재 코드의 내부 검증은 미측정
- 대회 진행 중, 순위는 변동(110위는 본인 확인 시점)
- 0.9558로 오른 변경은 저장소 문서에 아직 정리 전, 단계별 값은 0.9525까지
- 단어 하나 빠진 이름은 약함(영문 약 0.69, 한글 약 0.65, 모의 기준)
- 이름·톤수가 같은 자매선은 외부 DB 없이 구분 어려움

기술 · 기타

사용한 기술

Python · Llama 3.1 8B · Transformers · TRL · PEFT(LoRA) · bitsandbytes · pandas · numpy · PyMuPDF · python-docx · rhwp-python · Open WebUI · Ollama · ChromaDB · LightGBM · RapidFuzz · scikit-learn · PyTorch

AI 활용

AI 코딩 도구를 주로 코드를 쓰는 데 사용했고, 아이디어를 다듬거나 처음 접하는 분야를 공부할 때도 썼습니다. 수치와 동작은 직접 확인했고, 확인하지 못한 것은 성과로 쓰지 않았습니다.

AI에 맡긴 일	직접 한 일
코드 작성	결과 수치와 동작을 직접 확인
아이디어 정리와 도메인 학습 보조	확인하지 못한 내용은 성과로 쓰지 않기

수치 기준 표기

백테스트	과거 데이터 시뮬레이션
재현 시뮬레이션	체결·증거금 규칙을 적용한 원장 리플레이
평가셋 측정	정해진 평가 데이터로 잰 값
팀 측정	팀 전체 측정값(제 기여분만의 값이 아님)
운영 기록	실제로 돌린 기록

그 밖의 프로젝트

auto-mobility	실내 공간을 3D 모델로 복원하고 센서 데이터로 검증하는 온라인 현장실습 팀 프로젝트(3명). 저는 Visual SLAM 비교와 평가를 주로 맡았습니다.
K-Stock Engine	국내주식 다중 팩터 전략을 연구하고 가상 장부로 기록합니다. 아직 불완전한 단계라 성과는 싣지 않았습니다.
OIBC 2026	태양광 발전량 예측과 가상발전소(VPP) 배정 대회 프로젝트. 제출 전이라 점수는 싣지 않았습니다.

연락

xogud3624@gmail.com · github.com/KTHYEONG · kthyeong.github.io