데이터 엔지니어링 · 금융 IT 포트폴리오

# 김태형

TaeHyeong Kim

## 끊기고 겹치고 어긋난 데이터에서도 결과가 틀어지지 않게

경북대학교 컴퓨터학부 · 2027.02 졸업 예정
xogud3624@gmail.com · github.com/KTHYEONG · kthyeong.github.io

연결이 끊기면 빠진 구간을 어떻게 찾을까. 같은 요청이 두 번 나가면 어떻게 막을까. 검증 점수와 실제 점수가 다르면 어디부터 볼까. 아래 사례가 각각의 답입니다.

### 프로젝트

**01** **KRX-Alpha** 개인 진행 중
장중 시세 수집, 결손 탐지·보충 파이프라인

**02** **Port Entity Matching** 개인 진행 중
교차검증과 실제 점수의 차이를 원인별로 확인한 해운물류 매칭

**0.8162 → 0.9477**
이름 변형 시험 점수

**0.8805 → 0.9558**
공개 리더보드 점수

**03** **K-Closing Alpha** 개인
주문 전 기록으로 중복 주문을 막은 자동 집행 시스템

**04** **SaveTax** 개인 완료 보조
중복 집계·허위 후보를 막는 공공 조달 분석(해커톤)

**117건**
제출 건수

**약 13.7억 원**
접수 금액 합계

> **수치를 읽는 법**
> 모든 수치에 측정 방식을 표시했습니다. 실계좌 수익과 수상(Emori 팀 논문 제외)은 싣지 않았습니다. 진행 중인 대회의 점수와 순위는 확인한 시점의 값입니다. 근거는 각 저장소 README에 있습니다.

# KRX-Alpha 개인 진행 중

호가·체결 틱 수집·검증 데이터 파이프라인

증권사 실시간 API는 끊긴 구간의 체결을 다시 보내 주지 않습니다. 알파 연구 전에 틱 수집, 누락 보충, 모의 주문 검증 인프라를 먼저 만들었습니다. 알파 연구는 시작 전입니다.

기간 2026.09 ~ 진행 중

역할 수집·정규화·검증·백업·모의 주문 처리 단독 설계·구현

기술 Python | asyncio/WebSocket | Polars | PyArrow(Parquet) | SQLite | zstandard | Docker Compose | pytest

저장소 github.com/KTHYEONG/krx-alpha

| 코드 규모 | 테스트 | 개발 기간 |
|---|---|---|
| **약 3만 줄** | **약 2,860개** | **커밋 315개** |
| src 134개 파일 · 저장소 파일 집계 | def test_ 개수 · 파라미터 확장 전 | 2026-09-08부터 · git 이력 |

## 구조

| 선별 | 수집 | 검증 | 정규화 | 백업 |
|---|---|---|---|---|
| **종목 선별**<br>전일 종가 기준 | **웹소켓 수신**<br>원본 즉시 기록 | **누락 감사**<br>순번 빈틈 계산 | **원본을 정리본으로**<br>열 단위 파일로 변환 | **구글 드라이브 백업**<br>파일 크기 일치 확인 |
| | **주문 처리**<br>위험 한도 검사 후 집행 | **타사 보충**<br>키움·한국투자증권 체결 | **품질 검사**<br>중복 제거·이상값 확인 | **서버 파일 삭제**<br>백업 확인된 것만 |

일 단위 데몬이 수집부터 백업까지 순차 실행

## 사례

CASE 01

### 장중에는 받은 그대로 저장, 해석은 장 마감 후

| 수신 | 원본 기록 | 원본 보관 | 장마감 후 | 정리본 변환 |
|---|---|---|---|---|
| 실시간 시세 메시지 | 받은 시각만 붙임 | 압축 파일에 이어 저장 | 해석·중복 제거 | 열 단위 파일 + 품질 검사 |

**P 문제** 개장 직후 시세 메시지가 한꺼번에 몰립니다. 받으면서 내용을 해석하면 처리가 밀려 일부를 놓칠 수 있습니다.

**A 분석**
- 받자마자 해석: 단순하나 해석 오류가 곧 데이터 손실이라 제외
- 원본 먼저 저장: 해석 규칙을 고쳐도 다시 계산할 수 있어 선택

**A 실행**
- 수신 단계: 받은 시각만 붙여 압축 원본 파일에 이어 저장
- 해석·중복 제거·품질 검사: 장마감 후 원본에서 정리본으로 따로 처리

**R 결과** 받는 단계와 해석 단계를 코드상 분리. 실제 데이터 손실률은 측정하지 않음.

CASE 02

## 끊긴 구간을 체결 번호로 찾아 타사 자료로 보충

| 번호 감사 | 구간 확정 | 타사 보충 | 병합 | 출처 표시 |
|---|---|---|---|---|
| 종목별 빈 구간 계산 | 시간대·종목 특정 | 키움·한국투자증권 체결 이력 | 디스크 기반 정렬 | 별도 파일로 저장 |

**P 문제** 실시간 연결이 끊긴 동안의 체결 내역은 증권사가 다시 보내 주지 않아, 그대로 두면 영구히 빠집니다.

**A 분석**

- 같은 증권사에 재요청: 지나간 체결은 받을 수 없어 제외
- 타사 체결 이력 조회 사용, 먼저 빈 시간대·종목을 특정해야 함
- 원본 보호: 보충분은 출처를 붙여 별도 저장

**A 실행**

- 감사: 체결 번호가 비는 구간을 종목별로 계산
- 보충: 키움증권·한국투자증권 체결 이력으로 빈 구간 채움
- 병합: 디스크 기반 정렬로 합치며 중복 제거

**R 결과** 감사·보충·병합이 따로 실행되는 단계. 원본은 바꾸지 않음. 당일 체결만 제공하는 등 복구 불가 구간은 남을 수 있음.

### 한계

- 전략(알파) 단계 없음: 신호 생성·백테스트 엔진·수익 수치 없음
- 틱 손실 0 아님: 복구 불가 구간 가능, 모의 체결 현실성 미검증

# Port Entity Matching

개인 · 진행 중

입출항 기록을 표준 선박 한 척으로 잇는 매칭 파이프라인

DACON 항만 문제 해결 AI 대회 과제입니다. 오타·한글 표기·빈 제원이 섞인 입출항 기록 한 줄을 약 7만 8천 척의 표준 선박 중 하나로 연결합니다. 한글 선박명이 점수의 70%라 한글 매칭에 집중했습니다. 발음 코드와 LLM 후보로 시작해, 선박 카탈로그의 영문명을 한글로 바꿔 대조하는 역방향 채널까지 넣었습니다.

기간 2026.10 ~ 진행 중

역할 대회 개인 참가, 후보 검색·순위 모델·평가 도구 단독 구현

기술 Python · LightGBM · RapidFuzz · scikit-learn · PyTorch · Kanana 1.5 2.1B · pytest · uv

저장소 비공개 저장소

내부 검증 점수

**0.9910**

선박 단위 5분할 검증, LLM 후보 추가 전 모델

백테스트

이름 변형 시험 점수

**0.8162 → 0.9477**

단어 순서 바꾸기·빼기 등 20가지 변형, 내 컴퓨터 모의 기준

백테스트

공개 리더보드 점수

**0.8805 → 0.9558**

규칙 기반 방식 대비 현재 최고점, 진행 중 110위 (본인 확인)

운영 기록

## 구조




후보를 모은 뒤 랭커가 한 척을 고르는 구조

## 사례

CASE 01

### 내부 검증 0.9875 vs 대회 점수 0.8805, 원인 분리

**P 문제** 내 컴퓨터 검증 점수와 대회 리더보드 점수 차이가 컸습니다. 원인을 모른 채 모델을 고치면 제출만 낭비합니다.

**A 분석**

- 학습 때와 제출 때 처리 방식 불일치: 예측 차이 0건, 제외
- 처음 보는 선박 0.998, 영문 톤수 오차 0.9965, 영문 오타 0.957: 제외
- 단어 순서를 바꾸거나 단어가 빠지면 정확도 0.4~0.5로 하락
- 학습 데이터는 한 선박이 늘 같은 철자, 내부 검증으로 확인 불가
- 학습 모델의 한계: 철자·순서가 달라진 이름에 약함, 한글은 LLM 후보로 보완(사례 2)

**A 실행**

- 깨끗한 내부 검증 + 이름 변형 20가지 시험 병행
- 표기 증강 학습 추가
- 단어 순서와 무관한 검색, 순서가 바뀌어도 같은 값인 특징 7종 추가

**R 결과** 이름 변형 시험 점수 0.8162에서 0.9477, 단어 순서를 바꾼 영문 이름 정확도 0.486에서 0.999. 모의 변형 기준이라 실제 테스트에서 변형이 얼마나 있는지는 알 수 없습니다. 백테스트

**변형 시험 예시 (형식)**

| | | | |
|---|---|---|---|
| A B C | → | C A B | 단어 순서 바꿈 |
| A B C | → | A C | 단어 하나 빠짐 |
| A B C | → | A B-C | 철자·기호 표기 변화 |

**이름 변형 시험 점수 변화** 점수 백테스트




선박 단위 5분할 검증, 이름 변형 20가지 (내 컴퓨터)

### 한계

- 0.9910은 LLM 후보 추가 전 값, 현재 코드의 내부 검증은 미측정
- 대회 진행 중, 순위는 변동(110위는 본인 확인 시점)
- 0.9558로 오른 변경은 저장소 문서에 아직 정리 전, 단계별 값은 0.9525까지
- 단어 하나 빠진 이름은 약함(영문 약 0.69, 한글 약 0.65, 모의 기준)
- 이름·톤수가 같은 자매선은 외부 DB 없이 구분 어려움

# K-Closing Alpha 개인

장 마감 직전 정보로 종가에 사서 다음 날 시초가에 파는 퀀트

15:20에 볼 수 있는 정보만으로 종목 점수를 매기고, 상위 3종목을 종가에 사서 다음 날 시초가에 파는 전략을 연구·자동 실행합니다. 수익률보다 숫자가 부풀려질 곳을 먼저 막았습니다. 미래 정보 차단, 비용 반영, 검증, 중복 주문 방지를 프로그램 규칙으로 고정했습니다.

기간 2026

역할 데이터 수집, 예측 모델, 검증, 주문 실행 단독 설계·구현

기술 Python LightGBM pandas PyArrow(Parquet) aiohttp pydantic pytest systemd

저장소 github.com/KTHYEONG/k-closing-alpha

| 일평균 순수익 | 샤프지수(수익 대비 변동 크기) | 비용 민감도 | 검증한 전략 수 |
|---|---|---|---|
| **+34.58bp** | **2.73** | **4칸까지 이익** | **118개** |
| 886거래일(2023-01~2026-09), 세금·호가 비용·수수료 차감 후 (1bp=0.01%) | 승률 56.3%, 최대낙폭(고점 대비 최대 하락) 28.98% | 사고팔 때 호가 간격 비용을 1~6칸으로 바꿔 시험, 6칸에서 손실 | 연구 문서의 백테스트 표 기준 |
| 백테스트 | 백테스트 | 백테스트 | 백테스트 |

## 구조




## 사례

CASE 01

### 주문을 먼저 기록하고 체결 내역을 확인해 중복 주문 차단

| 의도 기록 | 주문 전송 | 응답 불확실 | 체결 내역 조회 | 인정/종결 |
|---|---|---|---|---|
| 주문 내용을 디스크에 저장 | 전송 사실 기록 | 미확인 상태로 표시 | 같은 주문 탐색 | 있으면 인정 |

**P 문제** 주문 후 증권사 응답이 오지 않으면 주문이 접수됐는지 알 수 없습니다. 다시 보내면 같은 종목을 두 번 사게 됩니다.

**A 분석**
- 재시도 횟수 제한: 이미 접수된 주문의 중복은 못 막아 제외
- 전송 전 기록 + 응답이 불확실하면 증권사 체결 내역 조회: 선택

**A 실행**
- 주문 의도와 전송 사실을 디스크에 먼저 기록
- 응답이 불확실하면 '미확인' 상태로 두고, 체결 내역에 같은 주문이 있으면 그 주문으로 인정, 없을 때만 종결
- 종가 확정 판단: 시각, 장 운영 상태, 현재가와 호가 가격 일치의 3조건

**R 결과** 주문 상태 변화, 기존 주문 인정, 종가 확정 판단을 구현하고 단위 테스트 작성. 실거래 운영 기록은 없음.

## 한계

- 수익 수치는 모두 백테스트, 실계좌·모의투자 손익 기록 없음
- 118개 중 고른 결과라 실제 성과는 더 낮을 수 있음
- 원본 데이터가 저장소에 없어 재현 불가, 비용은 내 계좌 수수료 기준

# SaveTax 개인 완료

시중가보다 비싼 납품 물품을 찾는 감사 도구

공공조달 공개 자료에서 시중가보다 비싸게 집행된 금액을 찾는 해커톤 참가작입니다. 중복 정리, 4종 비교 근거 수집, 사람 승인 후 제출 순서로 풀었습니다.

기간 2026.10

역할 나라장터 해커톤 참가작, 단독 설계·구현

기술 Python DuckDB Parquet Decimal pytest mypy ruff

저장소 비공개 저장소

| 중복 주문 보정 | 비교 가격 근거 | 제출 건수 | 접수 금액 합계 |
|---|---|---|---|
| **약 24%** | **4종** | **117건** | **약 13.7억 원** |
| 중복을 그대로 합산하면 부풀려지는 비율, 대회 안내 기준 | 타 계약·쇼핑몰·타 기관·부품 합산, 종류별 기준 배율 설정 | 접수 139건 중 철회 22건 제외, 모두 심사 대기(확정 전) 운영 기록 | 제출 117건의 접수 시 금액 합, 인정액 아님(확정 전) 운영 기록 |

## 사례

CASE 01

### 중복 주문 합계 보정, 데이터가 어긋나면 중단

| 불러오기 | 정합성 검사 | 불일치 중단 | 정리된 조회 화면 | 집계 |
|---|---|---|---|---|
| 데이터 파일 직접 조회 | 주문별 내용 일치 확인 | 오류로 멈춤 | 주문당 1건 | 빈 값은 0 아님 |

**P 문제** 같은 주문이 여러 물품 행에 반복돼 단순 합계가 부풀려집니다. 집계가 틀리면 이후 비싼 집행 판정이 모두 어긋납니다.

**A 분석**

- 합계 전 중복 제거 필요
- 계약번호·금액이 다르면 같은 주문으로 합치지 않음
- 주문 없는 물품(약 71%)은 0이 아닌 빈 값, 0 채움은 평균 왜곡으로 제외
- 어긋난 데이터는 넘기지 않고 불러오는 시점에 중단하기로 선택

**A 실행**

- DuckDB로 원본 데이터 파일을 바로 조회, 주문별로 내용 일치 검사
- 주문당 1건으로 정리한 조회 화면 생성, 불일치 시 오류로 중단
- 빈 값은 0으로 바꾸지 않고 빈 값으로 유지

**R 결과** 주문당 1건으로 집계하고 불일치 데이터는 중단. 약 24%는 중복 합산 시 부풀려지는 정도로, 대회 안내 수치.

## 한계

- 원본 데이터와 참가자 인증 정보가 저장소에 없어 전체 실행 재현 불가, 테스트는 합성 데이터.
- 과다 집행 판정은 시중가 비교 추정, 심사에서 근거 부족일 수 있음.
- 제출 건수·금액은 내 제출 기록 파일 기준(저장소 미포함), 심사 인정액과 다를 수 있음.
- 대회 결과는 확정 전이라 싣지 않음.

## 기술 · 기타

### 사용한 기술

Python · pytest · PyArrow(Parquet) · LightGBM · asyncio/WebSocket · Polars · SQLite · zstandard · Docker Compose · RapidFuzz · scikit-learn · PyTorch · Kanana 1.5 2.1B · uv · pandas · aiohttp · pydantic · systemd

### AI 활용

AI 코딩 도구를 주로 코드를 쓰는 데 사용했고, 아이디어를 다듬거나 처음 접하는 분야를 공부할 때도 썼습니다. 수치와 동작은 직접 확인했고, 확인하지 못한 것은 성과로 쓰지 않았습니다.

| AI에 맡긴 일 | 직접 한 일 |
|---|---|
| 코드 작성 | 결과 수치와 동작을 직접 확인 |
| 아이디어 정리와 도메인 학습 보조 | 확인하지 못한 내용은 성과로 쓰지 않기 |

### 수치 기준 표기

백테스트 과거 데이터 시뮬레이션 · 재현 시뮬레이션 체결·증거금 규칙을 적용한 원장 리플레이 · 평가셋 측정 정해진 평가 데이터로 잰 값 · 팀 측정 팀 전체 측정값(제 기여분만의 값이 아님) · 운영 기록 실제로 돌린 기록

### 그 밖의 프로젝트

**auto-mobility** 실내 공간을 3D 모델로 복원하고 센서 데이터로 검증하는 온라인 현장실습 팀 프로젝트(3명). 저는 Visual SLAM 비교와 평가를 주로 맡았습니다.

**K-Stock Engine** 국내주식 다중 팩터 전략을 연구하고 가상 장부로 기록합니다. 아직 불완전한 단계라 성과는 싣지 않았습니다.

**OIBC 2026** 태양광 발전량 예측과 가상발전소(VPP) 배정 대회 프로젝트. 제출 전이라 점수는 싣지 않았습니다.

### 연락

xogud3624@gmail.com · github.com/KTHYEONG · kthyeong.github.io