데이터 엔지니어링 · 금융 IT 포트폴리오

김태형

TaeHyeong Kim

끊기고 겹치고 어긋난 데이터에서도 결과가 틀어지지 않게

경북대학교 컴퓨터학부 · 2027.02 졸업 예정 · xogud3624@gmail.com · github.com/KTHYEONG

연결이 끊기면 빠진 구간을 어떻게 찾을까. 같은 요청이 두 번 나가면 어떻게 막을까. 검증 점수와 실제 점수가 다르면 어디부터 볼까. 아래 사례가 각각의 답입니다.

핵심 역량

수집 무결성

장중에는 파싱 없이 원본을 먼저 저장하고, 연결이 끊긴 구간은 순번으로 찾아 다른 증권사 API로 보충했습니다.

안전한 실행과 운영

주문을 보내기 전에 먼저 기록하고, 불확실하면 원장으로 확인해 중복 주문과 재실행 중복을 막았습니다.

데이터 정합성 검증

중복 집계로 부풀려진 합계를 멈추는 방식으로 막고, 검증 점수와 실제 점수의 차이는 원인을 나눠 확인했습니다.

대표 결과

Port Entity Matching

0.8805 → 0.9163

공개 리더보드 점수

규칙 v2 대비 LLM 후보 채널 (테스트 50%, 진행 중)

운영 기록

> **수치를 읽는 법**
>
> 모든 수치에 측정 방식을 표시했습니다. 실계좌 수익, 대회 순위, 수상(Emori 팀 논문 제외)은 싣지 않았습니다. 근거는 각 저장소 README에 있습니다.

프로젝트

01 KRX-Alpha 개인 진행 중

장중 시세 수집, 결손 탐지·보충 파이프라인

2026.09 ~ 진행 중 · 단독 설계·구현 (수집, 누락 감사·보충, 정규화, 백업·보존, 모의 OMS, 구조 검사 테스트)

github.com/KTHYEONG/krx-alpha

02 Port Entity Matching 개인 진행 중

교차검증과 실제 점수의 차이를 원인별로 확인한 해운물류 매칭

2026.10 ~ 진행 중 · 정규화, 후보 검색, 특징, 랭커, 평가 도구, 제출 코드를 단독 설계·구현했습니다.

0.8162 → 0.9477 스트레스 스위트 점수

교란 20개 시나리오, 로컬 모의 기준

백테스트

0.8805 → 0.9163 공개 리더보드 점수

규칙 v2 대비 LLM 후보 채널 (테스트 50%, 진행 중)

운영 기록

비공개 저장소

03 K-Closing Alpha 개인

주문 전 기록으로 중복 주문을 막은 자동 집행 시스템

2026 · 기획부터 주문 실행까지 단독 설계·구현

github.com/KTHYEONG/k-closing-alpha

04 SaveTax 개인 완료

중복 집계·허위 후보를 막는 공공 조달 분석(해커톤)

2026.10 · 개인 프로젝트, 설계·구현 단독. AI 도구로 코드를 작성했고, 설계 방향·비교 기준·동작 확인은 직접 했습니다.

약 24% 중복 주문 보정

중복 합산 시 부풀려지는 비율, 대회 안내 기준

코드로 확인

1,513개 단위 테스트

pytest 수집 기준, mypy strict·ruff 통과

코드로 확인

비공개 저장소

05 Quant Dashboard 개인

서버에 부담 주지 않는 상태 감시 대시보드

2026.10 ~ · 단독 설계·구현 (감시 대상 수집기와 데이터는 별도 프로젝트)

179개 통과 단위·계약 테스트

WSL pytest, 0.46초

코드로 확인

0개 런타임 의존성

표준 라이브러리만 사용

코드로 확인

비공개 저장소

사례

CASE 01 KRX-Alpha 개인

장중에는 원본만 기록, 파싱은 장 마감 후

수신	원본 기록	L0 보관	장마감 후	L1 변환
WebSocket 메시지	recv_ts만 붙임	jsonl.zst 이어쓰기	파싱·중복 제거	Parquet + 품질 검사

P 문제

개장 직후 메시지가 몰립니다. 수신 중 파싱하면 처리가 밀려 놓칠 수 있습니다.

A 분석

- 수신 즉시 정제: 단순하나 파싱 오류가 곧 손실이라 제외
- 원본 먼저 기록: 규칙을 고쳐도 재계산 가능해 선택

A 실행

- 수신 경로: recv_ts만 붙여 .jsonl.zst에 이어쓰기
- 파싱·중복 제거·품질 검사: 장마감 후 L0→L1 Parquet으로 분리

R 결과 코드로 확인

수신 경로와 해석 단계를 코드상 분리. 실제 손실률은 측정하지 않음.

CASE 02 KRX-Alpha 개인

끊긴 구간, 체결 순번으로 찾아 타사 API로 보충

순번 감사	구간 확정	타사 보충	병합	출처 표시
종목별 빈틈 계산	시간대·종목 특정	키움·KIS 체결 이력	SQLite 외부 정렬	별도 파일로 저장

P 문제

연결이 끊긴 구간의 체결은 증권사가 다시 보내 주지 않아 영구히 빠집니다.

A 분석

- 같은 증권사 재요청: 지나간 체결 수신 불가로 제외
- 타사 체결 이력 API 사용, 빈 시간대·종목 특정이 선행 조건
- 원본 보호: 보충분은 출처(vendor, provenance) 붙여 별도 저장

A 실행

- 감사: 체결 순번 빈틈을 종목별로 계산
- 보충: 키움 체결 이력·한국투자증권 API로 빈 구간 채움
- 병합: SQLite 외부 정렬로 합치며 중복 제거

R 결과 코드로 확인

감사, 보충, 병합이 독립 CLI 단계. L0 원본 미변경. 당일 체결만 제공하는 등 복구 불가 구간은 남을 수 있음.

CASE 03 Port Entity Matching 개인

교차검증 0.9875 vs 리더보드 0.8805, 원인 분리

P 문제

로컬 점수와 리더보드 차이가 컸습니다. 원인을 모른 채 모델을 고치면 제출만 낭비합니다.

A 분석

- 학습·서빙 경로 불일치: 예측 비교 차이 0건, 제외
- 미학습 선박 0.998, 라틴 톤수 잡음 0.9965, 라틴 오타 0.957: 제외
- 토큰 순서 변경·누락 시 정확도 0.4~0.5로 하락
- 학습 데이터는 한 선박이 늘 같은 철자, 교차검증으로 확인 불가

A 실행

- 깨끗한 교차검증 + 교란 20개 스트레스 스위트 병행
- 표기 증강 학습 추가
- 순서 무관 검색(정렬 키, 토큰 색인), 순서 불변 특징 7종 추가

R 결과 백테스트

스위트 점수 0.8162에서 0.9477, 토큰 순서를 바꾼 라틴 이름 정확도 0.486에서 0.999. 모의 교란 기준이며 실제 테스트 교란 비율은 알 수 없습니다.

스트레스 스위트 점수 변화 점수 백테스트



선박 단위 5-fold, 모의 교란 20개 시나리오 (로컬)

CASE 04 K-Closing Alpha 개인

주문 선기록과 원장 확인, 중복 주문 차단

의도 기록	주문 전송	응답 불확실	원장 조회	채택/종결
INTENT 디스크 저장	SEND 기록	UNKNOWN 상태	같은 주문 탐색	ADOPT 또는 종결

P 문제

주문 응답이 타임아웃되면 접수 여부를 모릅니다. 재전송하면 이중 매수가 됩니다.

A 분석

- 재시도 횟수 제한: 접수된 주문을 못 막아 제외
- 전송 전 기록 + 불확실 시 원장 조회: 선택

A 실행

- 주문 의도(INTENT)·전송(SEND)을 디스크에 먼저 기록
- 응답 불확실 시 UNKNOWN, 원장에 같은 주문 있으면 채택(ADOPT), 없을 때만 종결
- 종가 확정: 시각·장운영 구분코드·현재가와 호가 가격 일치 3조건

R 결과 코드로 확인

상태 전이·채택 로직·종가 확정 함수 구현, 단위 테스트 있음. 실거래 운영 기록은 없음.

CASE 05 SaveTax 개인

중복 주문 합계 보정, 불일치는 중단

로드	무결성 검사	불일치 중단	정규화 뷰	집계
Parquet 직접 조회	dlv_key별 일치 확인	오류로 멈춤	주문당 1건	빈 값은 0 아님

P 문제

같은 주문이 여러 물품에 반복돼 단순 합계가 부풀려집니다. 집계가 틀리면 이후 판정이 모두 어긋납니다.

A 분석

- 합계 전 중복 제거 필요
- 계약번호·금액이 다르면 합치지 않음
- 주문 없는 물품(약 71%)은 0이 아닌 빈 값, 0 채움은 평균 왜곡으로 제외
- 불일치를 넘기지 않고 로드 시점에 중단 선택

A 실행

- DuckDB로 Parquet 직접 조회, dlv_key별 일치 검사
- 주문당 1건 정규화 뷰 생성, 불일치 시 오류 중단
- 빈 값은 0으로 바꾸지 않고 유지

R 결과 코드로 확인

주문당 1건 뷰 사용, 불일치 데이터는 중단. 약 24%는 대회 안내 수치.

기술 · 기타

사용한 기술

Python pytest PyArrow(Parquet) LightGBM systemd mypy ruff asyncio/WebSocket Polars SQLite zstandard Docker Compose RapidFuzz scikit-learn PyTorch Kanana 1.5 2.1B uv pandas

AI 활용

AI 코딩 도구를 주로 코드를 쓰는 데 사용했고, 아이디어를 다듬거나 처음 접하는 분야를 공부할 때도 썼습니다. 수치와 동작은 직접 확인했고, 확인하지 못한 것은 성과로 쓰지 않았습니다.

AI에 맡긴 일	직접 한 일
코드 작성	결과 수치와 동작을 직접 확인
아이디어 정리와 도메인 학습 보조	확인하지 못한 내용은 성과로 쓰지 않기

프로젝트별 한계

- **KRX-Alpha** 전략(알파) 단계 없음: 신호 생성·백테스트 엔진·수익 수치 없음
- **Port Entity Matching** 0.9910은 LLM 채널 추가 전 값, 현재 코드 교차검증은 미측정
- **K-Closing Alpha** 수익 수치는 모두 백테스트, 실계좌·모의투자 손익 기록 없음
- **SaveTax** data/와 참가자 토큰이 저장소에 없어 CLI 전체 재현 불가, 테스트는 합성 데이터.
- **Quant Dashboard** 감시 대상 데이터·로그가 저장소에 없어 다른 환경에서 재현 어려움

수치 기준 표기

백테스트 과거 데이터 시뮬레이션 재현 시뮬레이션 체결·증거금 규칙을 적용한 원장 리플레이 평가셋 측정 정해진 평가 데이터로 잰 값
팀 측정 팀 전체 측정값(제 기여분만의 값이 아님) 운영 기록 실제로 돌린 기록 코드로 확인 코드·설정·테스트로 확인한 설계 사실

그 밖의 프로젝트

auto-mobility 실내 공간을 3D 모델로 복원하고 센서 데이터로 검증하는 온라인 현장실습 팀 프로젝트(3명). 저는 Visual SLAM 비교와 평가를 주로 맡았습니다.

K-Stock Engine 국내주식 다중 팩터 전략을 연구하고 가상 장부로 기록합니다. 아직 불완전한 단계라 성과는 싣지 않았습니다.

OIBC 2026 태양광 발전량 예측과 가상발전소(VPP) 배정 대회 프로젝트. 제출 전이라 점수는 싣지 않았습니다.

연락 xogud3624@gmail.com · github.com/KTHYEONG