데이터 엔지니어링 · 금융 IT 포트폴리오

김태형

TaeHyeong Kim

끊기고 겹치고 어긋난 데이터에서도 결과가 틀어지지 않게

경북대학교 컴퓨터학부 · 2027.02 졸업 예정 · xogud3624@gmail.com · github.com/KTHYEONG

연결이 끊기면 빠진 구간을 어떻게 찾을까. 같은 요청이 두 번 나가면 어떻게 막을까. 검증 점수와 실제 점수가 다르면 어디부터 볼까. 아래 사례가 각각의 답입니다.

핵심 역량

수집 무결성

장중에는 파싱 없이 원본을 먼저 저장하고, 연결이 끊긴 구간은 순번으로 찾아 다른 증권사 API로 보충했습니다.

안전한 실행과 운영

주문을 보내기 전에 먼저 기록하고, 불확실하면 원장으로 확인해 중복 주문과 재실행 중복을 막았습니다.

데이터 정합성 검증

중복 집계로 부풀려진 합계를 멈추는 방식으로 막고, 검증 점수와 실제 점수의 차이는 원인을 나눠 확인했습니다.

대표 결과

Port Entity Matching

0.8805 → 0.9163

공개 리더보드 점수

규칙 기반 방식 대비 LLM 후보 추가 (테스트 50%, 진행 중)

운영 기록

> **수치를 읽는 법**
>
> 모든 수치에 측정 방식을 표시했습니다. 실계좌 수익, 대회 순위, 수상(Emori 팀 논문 제외)은 싣지 않았습니다. 근거는 각 저장소 README에 있습니다.

프로젝트

01 KRX-Alpha 개인 진행 중

장중 시세 수집, 결손 탐지·보충 파이프라인

2026.09 ~ 진행 중 · 단독 설계·구현 (수집, 누락 감사·보충, 정규화, 백업·보존, 모의 주문 처리, 구조 검사 테스트)

github.com/KTHYEONG/krx-alpha

02 Port Entity Matching 개인 진행 중

교차검증과 실제 점수의 차이를 원인별로 확인한 해운물류 매칭

2026.10 ~ 진행 중 · 정규화, 후보 검색, 특징, 랭커, 평가 도구, 제출 코드를 단독 설계·구현했습니다.

0.8162 → 0.9477 이름 변형 시험 점수

단어 순서 바꾸기·빼기 등 20가지 변형, 내 컴퓨터 모의 기준

백테스트

0.8805 → 0.9163 공개 리더보드 점수

규칙 기반 방식 대비 LLM 후보 추가 (테스트 50%, 진행 중)

운영 기록

비공개 저장소

03 K-Closing Alpha 개인

주문 전 기록으로 중복 주문을 막은 자동 집행 시스템

2026 · 기획부터 주문 실행까지 단독 설계·구현

github.com/KTHYEONG/k-closing-alpha

04 SaveTax 개인 완료

중복 집계·허위 후보를 막는 공공 조달 분석(해커톤)

2026.10 · 개인 프로젝트, 설계·구현 단독. AI 도구로 코드를 작성했고, 설계 방향·비교 기준·동작 확인은 직접 했습니다.

117건 제출 건수

접수 139건 중 철회 22건 제외, 모두 심사 대기(확정 전)

운영 기록

약 13.7억 원 접수 금액 합계

제출 117건의 접수 시 금액 합, 인정액 아님(확정 전)

운영 기록

비공개 저장소

사례

CASE 01 KRX-Alpha 개인

장중에는 받은 그대로 저장, 해석은 장 마감 후

수신	원본 기록	원본 보관	장마감 후	정리본 변환
실시간 시세 메시지	받은 시각만 붙임	압축 파일에 이어 저장	해석·중복 제거	열 단위 파일 + 품질 검사

P 문제 개장 직후 시세 메시지가 한꺼번에 몰립니다. 받으면서 내용을 해석하면 처리가 밀려 일부를 놓칠 수 있습니다.

A 분석
- 받자마자 해석: 단순하나 해석 오류가 곧 데이터 손실이라 제외
- 원본 먼저 저장: 해석 규칙을 고쳐도 다시 계산할 수 있어 선택

A 실행
- 수신 단계: 받은 시각만 붙여 압축 원본 파일에 이어 저장
- 해석·중복 제거·품질 검사: 장마감 후 원본에서 정리본으로 따로 처리

R 결과 받는 단계와 해석 단계를 코드상 분리. 실제 데이터 손실률은 측정하지 않음.

CASE 02 KRX-Alpha 개인

끊긴 구간을 체결 번호로 찾아 타사 자료로 보충

번호 감사	구간 확정	타사 보충	병합	출처 표시
종목별 빈 구간 계산	시간대·종목 특정	키움·한국투자증권 체결 이력	디스크 기반 정렬	별도 파일로 저장

P 문제 실시간 연결이 끊긴 동안의 체결 내역은 증권사가 다시 보내 주지 않아, 그대로 두면 영구히 빠집니다.

A 분석
- 같은 증권사에 재요청: 지나간 체결은 받을 수 없어 제외
- 타사 체결 이력 조회 사용, 먼저 빈 시간대·종목을 특정해야 함
- 원본 보호: 보충분은 출처를 붙여 별도 저장

A 실행
- 감사: 체결 번호가 비는 구간을 종목별로 계산
- 보충: 키움증권·한국투자증권 체결 이력으로 빈 구간 채움
- 병합: 디스크 기반 정렬로 합치며 중복 제거

R 결과 감사·보충·병합이 따로 실행되는 단계. 원본은 바꾸지 않음. 당일 체결만 제공하는 등 복구 불가 구간은 남을 수 있음.

CASE 03 Port Entity Matching 개인

내부 검증 0.9875 vs 대회 점수 0.8805, 원인 분리

P 문제 내 컴퓨터 검증 점수와 대회 리더보드 점수 차이가 컸습니다. 원인을 모른 채 모델을 고치면 제출만 낭비합니다.

A 분석

- 학습 때와 제출 때 처리 방식 불일치: 예측 차이 0건, 제외
- 처음 보는 선박 0.998, 영문 톤수 오차 0.9965, 영문 오타 0.957: 제외
- 단어 순서를 바꾸거나 단어가 빠지면 정확도 0.4~0.5로 하락
- 학습 데이터는 한 선박이 늘 같은 철자, 내부 검증으로 확인 불가
- 학습 모델의 한계: 철자·순서가 달라진 이름에 약함, 한글은 LLM 후보로 보완(사례 2)

A 실행

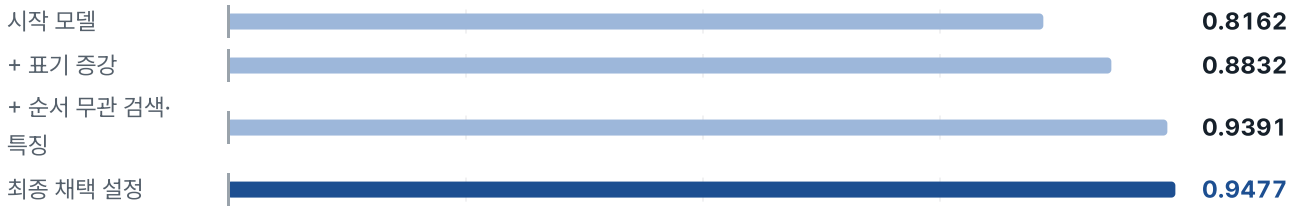
- 깨끗한 내부 검증 + 이름 변형 20가지 시험 병행
- 표기 증강 학습 추가
- 단어 순서와 무관한 검색, 순서가 바뀌어도 같은 값인 특징 7종 추가

R 결과 이름 변형 시험 점수 0.8162에서 0.9477, 단어 순서를 바꾼 영문 이름 정확도 0.486에서 0.999. 모의 변형 기준이라 실제 테스트에서 변형이 얼마나 있는지는 알 수 없습니다. 백테스트

변형 시험 예시 (형식)

A B C	→	C A B	단어 순서 바꿈
A B C	→	A C	단어 하나 빠짐
A B C	→	A B-C	철자·기호 표기 변화

이름 변형 시험 점수 변화 점수 백테스트



선박 단위 5분할 검증, 이름 변형 20가지 (내 컴퓨터)

CASE 04 K-Closing Alpha 개인

주문을 먼저 기록하고 체결 내역을 확인해 중복 주문 차단

의도 기록	주문 전송	응답 불확실	체결 내역 조회	인정/종결
주문 내용을 디스크에 저장	전송 사실 기록	미확인 상태로 표시	같은 주문 탐색	있으면 인정

P 문제 주문 후 증권사 응답이 오지 않으면 주문이 접수됐는지 알 수 없습니다. 다시 보내면 같은 종목을 두 번 사게 됩니다.

A 분석

- 재시도 횟수 제한: 이미 접수된 주문의 중복은 못 막아 제외
- 전송 전 기록 + 응답이 불확실하면 증권사 체결 내역 조회: 선택

A 실행

- 주문 의도와 전송 사실을 디스크에 먼저 기록
- 응답이 불확실하면 '미확인' 상태로 두고, 체결 내역에 같은 주문이 있으면 그 주문으로 인정, 없을 때만 종결
- 종가 확정 판단: 시각, 장 운영 상태, 현재가와 호가 가격 일치의 3조건

R 결과 주문 상태 변화, 기존 주문 인정, 종가 확정 판단을 구현하고 단위 테스트 작성. 실거래 운영 기록은 없음.

CASE 05 SaveTax 개인

중복 주문 합계 보정, 데이터가 어긋나면 중단

불러오기	정합성 검사	불일치 중단	정리된 조회 화면	집계
데이터 파일 직접 조회	주문별 내용 일치 확인	오류로 멈춤	주문당 1건	빈 값은 0 아님

P 문제 같은 주문이 여러 물품 행에 반복돼 단순 합계가 부풀려집니다. 집계가 틀리면 이후 비싼 집행 판정이 모두 어긋납니다.

A 분석

- 합계 전 중복 제거 필요
- 계약번호·금액이 다르면 같은 주문으로 합치지 않음
- 주문 없는 물품(약 71%)은 0이 아닌 빈 값, 0 채움은 평균 왜곡으로 제외
- 어긋난 데이터는 넘기지 않고 불러오는 시점에 중단하기로 선택

A 실행

- DuckDB로 원본 데이터 파일을 바로 조회, 주문별로 내용 일치 검사
- 주문당 1건으로 정리한 조회 화면 생성, 불일치 시 오류로 중단
- 빈 값은 0으로 바꾸지 않고 빈 값으로 유지

R 결과 주문당 1건으로 집계하고 불일치 데이터는 중단. 약 24%는 중복 합산 시 부풀려지는 정도로, 대회 안내 수치.

기술 · 기타

사용한 기술

Python · pytest · PyArrow(Parquet) · LightGBM · asyncio/WebSocket · Polars · SQLite · zstandard · Docker Compose · RapidFuzz · scikit-learn · PyTorch · Kanana 1.5 2.1B · uv · pandas · aiohttp · pydantic · systemd

AI 활용

AI 코딩 도구를 주로 코드를 쓰는 데 사용했고, 아이디어를 다듬거나 처음 접하는 분야를 공부할 때도 썼습니다. 수치와 동작은 직접 확인했고, 확인하지 못한 것은 성과로 쓰지 않았습니다.

AI에 맡긴 일	직접 한 일
코드 작성	결과 수치와 동작을 직접 확인
아이디어 정리와 도메인 학습 보조	확인하지 못한 내용은 성과로 쓰지 않기

프로젝트별 한계

- **KRX-Alpha** 전략(알파) 단계 없음: 신호 생성·백테스트 엔진·수익 수치 없음
- **Port Entity Matching** 0.9910은 LLM 후보 추가 전 값, 현재 코드의 내부 검증은 미측정
- **K-Closing Alpha** 수익 수치는 모두 백테스트, 실계좌·모의투자 손익 기록 없음
- **SaveTax** 원본 데이터와 참가자 인증 정보가 저장소에 없어 전체 실행 재현 불가, 테스트는 합성 데이터.

수치 기준 표기

백테스트 과거 데이터 시뮬레이션 · 재현 시뮬레이션 체결·증거금 규칙을 적용한 원장 리플레이 · 평가셋 측정 정해진 평가 데이터로 잰 값 · 팀 측정 팀 전체 측정값(제 기여분만의 값이 아님) · 운영 기록 실제로 돌린 기록

그 밖의 프로젝트

auto-mobility 실내 공간을 3D 모델로 복원하고 센서 데이터로 검증하는 온라인 현장실습 팀 프로젝트(3명). 저는 Visual SLAM 비교와 평가를 주로 맡았습니다.

K-Stock Engine 국내주식 다중 팩터 전략을 연구하고 가상 장부로 기록합니다. 아직 불완전한 단계라 성과는 싣지 않았습니다.

OIBC 2026 태양광 발전량 예측과 가상발전소(VPP) 배정 대회 프로젝트. 제출 전이라 점수는 싣지 않았습니다.

연락 xogud3624@gmail.com · github.com/KTHYEONG