데이터 엔지니어링 · 금융 IT 포트폴리오

김태형

TaeHyeong Kim

데이터를 수집하고 검증하는 시스템을 만들었습니다

경북대학교 컴퓨터학부 · 2027.02 졸업 예정
xogud3624@gmail.com · github.com/KTHYEONG · kthyeong.github.io

끊기거나 겹치거나 틀릴 수 있는 데이터를 믿고 쓸 수 있게 만드는 일을 해 왔습니다. 수집은 원본부터 저장하고 빠진 구간을 채우며, 실행은 기록을 먼저 남겨 재시도해도 중복되지 않게 하고, 분석은 미래 정보와 중복 집계가 섞이지 않게 막았습니다.

프로젝트

01 KRX-Alpha 개인 진행 중

증권사 실시간 시세는 끊기면 다시 받을 수 없습니다. 여러 증권사의 틱을 받은 그대로 먼저 저장하고 빠진 구간을 채우는 수집 파이프라인을 만들었고, 임대 서버(VPS)에서 매일 자동으로 감사·백업·점검합니다. 접속 키와 비밀값은 암호화해 따로 보관합니다.

0.04~0.42%
장 마감 후 감사로 잰 수신 손실률 (11.5~11.6, 하루 약 610만 건 처리)

불일치 0건
삭제 전 점검: 로컬 정리본 1,166개 중 1,155개가 드라이브와 md5 일치 (나머지 11개는 대기)

02 K-Closing Alpha 개인 진행 중

자동 주문은 네트워크가 끊겨 다시 실행하면 같은 주문이 두 번 나갈 수 있습니다. 주문을 보내기 전에 먼저 기록하고 응답이 불확실하면 체결 내역으로 확인해 중복 주문을 막은, 종가매매 자동 집행 시스템을 만들었습니다.

모의투자 리허설 중
2026.10.12부터 서버에서 가동, 미확인 주문 이월 복구와 실거래 한도 명시 강제 추가

+31.27bp
이 전략의 일평균 순수익 (백테스트, 비용 차감 후)

03 Port Entity Matching 개인 완료 보조

교차검증과 대회 점수의 차이를 원인별로 확인한 선박 기록 매칭

0.8162 → 0.9477
이름 변형 시험 점수 (내 컴퓨터)

0.9595 → 0.91989
공개 → 비공개 점수 (원인 미분석)

04 SaveTax 개인 완료 보조

반려 사유를 분석해 이의 41건으로 대응한 공공 조달 분석(해커톤)

45위 / 1,169명
최종 순위 (공식 결과)

5.93억 원
확정 인정 금액 (수정 반영 접수 약 11.1억 원)

05 OIBC 2026 개인 진행 중 보조

마감 시각 이후 정보를 데이터 단계에서 막은 태양광 발전량 예측 대회 파이프라인(제출 중)

전날 17:00 이후 차단
예보 발행 시각이 마감을 넘으면 오류로 중단

969개
테스트 (파라미터 확장 전)

> **도움말**
>
> 모든 수치에 측정 방식(백테스트·운영 기록·코드 확인 등)을 표시했고, 확인하지 못한 내용은 성과로 쓰지 않았습니다. 실계좌 수익은 싣지 않았고, 수상은 Emori 팀 논문 수상만 적었습니다. 대회 순위는 확정된 최종 결과 기준이며, 진행 중인 대회는 점수를 싣지 않았습니다. 대회 원본 데이터와 인증 정보는 저장소에 없어 전체 재현이 안 되는 프로젝트가 있습니다. 근거는 각 저장소 README에 있습니다.

KRX-Alpha 개인 진행 중

호가·체결 틱 수집·검증 데이터 파이프라인

증권사 실시간 API는 끊긴 구간을 다시 보내 주지 않아, 받은 그대로 먼저 저장하고 빠진 구간은 장 마감 후 감사해 채웁니다. 감사 기준 수신 손실은 0.04~0.42%이고, 알파(초과수익) 연구는 시작 전입니다.

기간 2026.09 ~ 진행 중

역할 수집·정규화·검증·백업·서버 운영·모의 주문 처리 단독 설계·구현

규모 src 약 3.6만 줄 · 테스트 약 3,500개 · 커밋 364개 (2026-11-09 기준)

기술 Python | asyncio/WebSocket | Polars | PyArrow(Parquet) | SQLite | zstandard | Docker Compose | pytest

저장소 github.com/KTHYEONG/krx-alpha

장 마감 후 감사 손실률

0.04% ~ 0.42%

11.6 0.04%(2,612/6,127,713건), 11.5 0.42%(25,938/6,122,358건), 세션 감사 기준, 이후 야간 보충

운영 기록

구조



데몬이 수신·스냅샷·교차 확인을 병렬 자식 프로세스로 띄우고, 장 마감 후 감사·보충·정규화·백업 순서로 처리. 주문 처리는 수집과 별개 경로

사례

CASE 01

원본 먼저 저장, 해석은 장 마감 후

수신	원본 기록	원본 보관	장마감 후	정리본 변환
실시간 시세 메시지	받은 시각만 붙임	압축 파일에 이어 저장	해석·중복 제거	열 단위 파일 + 품질 검사

P 문제 개장 직후 시세 메시지가 한꺼번에 몰립니다. 받으면서 내용을 해석하면 처리가 밀려 일부를 놓칠 수 있습니다.

0.04%
11.6 손실, 2,612 / 6,127,713건

0.42%
11.5 손실, 25,938 / 6,122,358건

2.0%
10.29 손실, 89,545 / 4,438,186건, 장 시작 직후 전달 지연 구간 포함

A 분석
- 받자마자 해석은 단순하나 해석 오류가 곧 데이터 손실이라 제외, 원본 먼저 저장하면 규칙을 고쳐도 다시 계산 가능

A 실행
- 수신 단계는 받은 시각만 붙여 압축 원본에 이어 저장, 해석·중복 제거·품질 검사는 장 마감 후 따로 처리

R 결과
수신과 해석을 분리했고, 수신 손실은 장 마감 후 세션 감사가 측정합니다. 손실이 컸던 날은 장 시작 직후 증권사 전달 지연이 있었고(10.20·10.27·10.29, 최대 64초), 이후 야간 보충으로 채웁니다. 운영 기록

CASE 02

끊긴 구간을 체결 번호로 찾아 보충

번호 감사	구간 확정	타사 보충	병합	출처 표시
종목별 빈 구간 계산	시간대·종목 특정	키움·한국투자증권 체결 이력	디스크 기반 정렬	별도 파일로 저장

P 문제
실시간 연결이 끊긴 동안의 체결 내역은 증권사가 다시 보내 주지 않아, 그대로 두면 영구히 빠집니다.

A 분석
- 같은 증권사에 재요청은 지나간 체결을 받을 수 없어 제외, 먼저 빈 시간대·종목을 특정해야 함
- 원본 보호: 보충분은 출처를 붙여 별도 저장하고, 보충량이 허용 오차(2%)를 넘으면 병합 보류

A 실행
- 체결 번호가 비는 구간을 종목별로 계산해 키움증권·한국투자증권 체결 이력으로 채우고 중복 제거
- 10.30·11.2분은 오차 초과로 병합이 보류됐고, 원인이던 감사의 이중 집계를 수정한 뒤 보충 완료

R 결과
감사·보충·병합을 따로 실행하고 원본은 바꾸지 않습니다. 증권사가 당일 체결만 제공하는 구간은 영구히 복구되지 않았고, 날짜별로 운영 점검 문서에 기록했습니다. 운영 기록

1,252건
10.20 영구 복구 불가 체결

329건
10.22 영구 복구 불가 체결

한계

미검증 **전략(알파) 단계 없음**
신호 생성·백테스트 엔진·수익 수치가 없고 현재는 수집·검증 인프라 단계입니다.

해석 주의 **손실이 0은 아님**
장 시작 직후 증권사 전달 지연으로 0.04~2.0%대 손실이 반복됐고, 복구 불가 구간(10.20 1,252건 등)이 있습니다.

미검증 **원본 먼저 저장의 효과**
원본 먼저 저장이 손실을 줄였는지 비교한 대조 실험은 없습니다.

미검증 **모의 주문과 서버 설정의 범위**

모의 주문(OMS)은 코드와 테스트로만 확인해 정기 실행이 없고 체결 현실성은 미검증이며, 서버 점검표·비밀값 설정은 저장소만으로 재현할 수 없습니다.

K-Closing Alpha 개인 진행 중

장 마감 직전 정보로 종가에 사서 다음 날 시초가에 파는 퀀트

15:20에 볼 수 있는 정보만으로 상위 3종목을 종가에 사서 다음 날 시초가에 파는 전략에, 미래 정보 차단·비용 반영·중복 주문 방지를 프로그램 규칙으로 고정했습니다. 백테스트 일평균 순수익은 +31.27bp(1bp=0.01%)이고, 2026.10.12부터 모의투자로 운영 경로를 리허설 중입니다.

기간 2025.12 ~ 진행 중

역할 데이터 수집, 예측 모델, 검증, 주문 실행 단독 설계·구현

기술 Python LightGBM pandas PyArrow(Parquet) aiohttp pydantic pytest systemd

저장소 github.com/KTHYEONG/k-closing-alpha

일평균 순수익

+31.27bp

운영 전략(LGBM 상위 3종목 균등 가중), 886거래일(2023-01~2026-09), 연구 문서 §7 기준 (1bp=0.01%)

백테스트

샤프지수(수익 대비 변동 크기)

2.57

같은 전략의 최대낙폭(고점 대비 최대 하락) 25.03%

백테스트

구조



사례

CASE 01

주문 전 기록으로 중복 주문 차단

의도 기록	주문 전송	응답 불확실	체결 내역 조회	인정/종결
주문 내용을 디스크에 저장	전송 사실 기록	미확인 상태로 표시	같은 주문 탐색	있으면 인정

P **문제** 주문 후 증권사 응답이 오지 않으면 주문이 접수됐는지 알 수 없습니다. 다시 보내면 같은 종목을 두 번 사게 됩니다.

09.21 하루 두 번 도는 진입 단계에서 두 번째 실행이 줄어든 현금으로 다시 사이징해, 체결된 주문을 더 작은 주문으로 덮어씀(예: 301주→50주). 당일 진입 기록이 있으면 건너뛰도록 수정

10.12 **임대 서버(VPS)의 주문 경로를 모의투자로 전환해 리허설 시작. 모의 장중 조회가 1.3~4.6초 걸려 5초 제한에 가깝고, 취소된 주문 행이 기존 주문 후보로 오인될 수 있어 보정**

10.15 전일 미확인 주문의 이월 복구와 운영자 수동 해소 경로 추가

11.07 실거래 주문 한도를 환경변수로 명시하지 않으면 실거래 연결을 거부

A 실행
- 주문 의도와 전송 사실을 먼저 기록하고, 응답이 불확실하면 체결 내역에 같은 주문이 있을 때만 인정, 종가 확정은 시각·장 운영 상태·가격 일치 3조건으로 판단

R 결과 주문 상태 변화, 기존 주문 인정, 종가 확정 판단을 구현해 단위 테스트를 작성했고, 모의투자 리허설에서 나온 결함을 고쳤습니다. 운영 기록

한계

해석 주의 **수익은 모두 백테스트**
실계좌·모의투자 손익 기록이 없고 모의투자는 운영 경로 리허설 단계이며, 비용은 내 계좌 수수료 기준입니다.

해석 주의 **118개 중 고른 선택 편향**
대표 수치(+31.27bp)는 운영 전략 기준이고 편향 보정 결과는 없으며, 연구용 변형 +34.58bp에는 운영 경로에 없는 역틱 가중이 들어 있습니다.

해석 주의 **연구 문서의 불일치**
2틱 조건의 두 표가 +34.58bp와 +32.36bp를 모두 샤프 2.73으로 적고 비용 상한 비교의 조건이 섞여 있으며, 룩어헤드 수정 전후 차이는 기록이 없습니다.

미검증 **근거 문서가 저장소 밖**
연구 문서가 저장소 밖에 있고 원본 데이터가 없어 재검증이 어렵습니다.

보조 프로젝트

Port Entity Matching 개인 완료

입출항 기록을 표준 선박 한 척으로 잇는 매칭 파이프라인

해양수산부 주최 DACON 대회에서 오타·한글 표기·빈 제원이 섞인 입출항 기록을 표준 선박 한 척에 잇는 과제를 풀었습니다. 한글 선박명 비중이 커서 발음 코드·LLM 후보·역방향 채널(카탈로그 영문명을 한글로 바꿔 대조)로 보강했고, 468명 중 106위로 마쳤습니다.

기간 2026.10 ~ 2026.11

역할 대회 개인 참가, 후보 검색·순위 모델·평가 도구 단독 구현

기술 Python LightGBM RapidFuzz scikit-learn PyTorch Kanana 1.5 2.1B Midm 2.0 Mini pytest uv

저장소 github.com/KTHYEONG/port-entity-matching

비공개 리더보드 최종
0.91989
468명 중 106위, 테스트 100% 기준 최종 순위. 공개 0.9595에서 약 0.04 낮아졌고 원인은 분석하지 못했음
운영 기록

공개 리더보드 점수
0.8805 → 0.9595
테스트 50% 기준, 규칙 기반 대비 최종 제출물 (한글 507/532)
운영 기록

이름 변형 시험 점수
0.8162 → 0.9477
단어 순서 바꾸기·빼기 등 20가지 변형, 내 컴퓨터 모의 기준
백테스트

사례

CASE 01
검증 점수와 대회 점수의 격차 추적

P 문제 내 컴퓨터 검증 점수(0.9875, 이른 v2 모델)와 대회 공개 점수(0.8805)의 차이가 컸습니다. 원인을 모른 채 모델을 고치면 제출만 낭비합니다.

가설 → 확인 방법 → 결과

	확인 방법	결과 선택
학습·제출 처리 방식 불일치	저장·불러오기 경로와 내부 검증 예측 비교	다른 예측 0건, 제외
처음 보는 선박	학습에 없는 카탈로그 선박의 합성 기록	정확도 0.998, 제외
영문 톤수 오차	±10~20% 오차 시험	0.9965, 제외
영문 오타	2~4자 오타 합성 기록	0.957, 제외
단어 순서·빠짐	표기 변형 시험	정확도 0.4~0.7로 하락, 원인

이름 변형 시험 점수 변화 점수 백테스트



선박 단위 5분할 검증, 이름 변형 20가지 (내 컴퓨터)

A 실행
- 학습 데이터는 한 선박이 늘 같은 철자라 내부 검증으로 못 보므로, 깨끗한 검증과 이름 변형 20가지 시험을 병행
- 표기 증강 학습 추가
- 단어 순서와 무관한 검색, 순서가 바뀌어도 같은 값인 특징 7종 추가

R 결과 이름 변형 시험 점수가 크게 올랐고(결과 카드 참고), 단어 순서를 바꾼 영문 이름 정확도는 0.486에서 0.999가 됐습니다(모의 변형 기준). 백테스트

한계

미검증 **공개→비공개 하락 원인 미분석**
공개 대비 비공개 점수가 약 0.04 낮아진 원인(결과 카드 참고)을 설명하지 못했고, 내 컴퓨터의 모의 오류로는 리더보드의 한글 오류가 재현되지 않습니다.

미검증 **규칙 해석 위험**
역방향 채널의 허용 여부를 운영진에게 직접 확인받지 못했고(공식 답변은 학습 데이터 기반 LLM 증강까지), 학습 선박 제외는 분할 구조를 이용한 규칙입니다.

해석 주의 **공개 리더보드 반복 확인**
점수 개선을 공개 리더보드(테스트 50%)로 반복 확인했고 비공개 하락과의 관계는 확인하지 못했으며, 정답 추정 도구(evaluation/lb)는 개발 전용입니다.

해석 주의 **모의 기준 수치와 추정 시간**
추론 약 16분은 서버(L4) 미실측 추정이고, 단어 하나 빠진 이름은 약하며(영문 약 0.69·한글 약 0.65) 변형 시험은 모의라 실제 비율은 알 수 없습니다.

SaveTax 개인 완료

시중가보다 비싼 납품 물품을 찾아 근거와 함께 제보하는 분석 도구

공공조달 자료에서 시중가보다 비싼 집행을 찾아, 중복 주문 정리와 사람 승인 뒤 제출 흐름으로 안전하게 제보했습니다. 잠정 판정의 반려 건에는 이의로 대응해 참가자 1,169명 중 45위로 마쳤습니다.

기간 2026.10

역할 나라장터 해커톤 참가작, 단독 설계·구현

규모 src 약 1.2만 줄 · 테스트 1,513개

기술 Python DuckDB Parquet Decimal pytest mypy ruff

저장소 github.com/KTHYEONG/SaveTax

최종 순위
45위 / 1,169명
확정 금액이 있는 참가자 115명 중 45위, 참가자 대부분은 확정 금액 없음 (공식 결과 2026.11.9)
운영 기록

확정 인정 금액
5.93억 원
잠정 판정(10.30)의 인정·부분 인정 18건 약 1.16억 원에서 이의 처리 후 확정, 수정 반영 접수 금액 약 11.1억 원의 약 53% (공식 결과 2026.11.9)
운영 기록

이의 제기
41건
잠정 반려 31·판단 유보 4·부분 인정 6건, 신고액 합계 약 5.17억 원, 10.30에 33건·11.5에 8건 접수
운영 기록

사례

CASE 01

반려 사유 분류와 이의 41건 대응

문제 마감 뒤 잠정 판정에서 결과가 공개된 74건 중 52건이 반려됐고, 52건 모두 사유에 '근거 링크가 판매 페이지가 아님'이 있었습니다. 이의 기간은 11.6까지였습니다.

- 10.30 **잠정 판정 공개: 74건 중 인정 12, 부분 인정 6, 판단 유보 4, 반려 52**
- 10.30 반려 사유를 랙·데스크톱·패치패널 유형으로 나눠 이의문을 쓰고 33건 접수
- 11.5 남은 반려 건 8건을 추가 접수
- 11.6 이의 기간 마감
- 11.9 **최종 결과 발표, 인정액 확정**

반려 유형 → 이의 논지

랙: 공임 페이지를 판매 근거로 오인	→	**판매가와 가산액을 분리**	가산액은 주최 측 표준품셈 페이지 값임을 설명하고, 같은 구조로 인정된 제출을 인용
데스크톱: 판매 페이지 아님	→	**화면에 보이는 판매가 제시**	JS로 그려져 원본 HTML만 읽으면 비어 보임, 일부 건은 금액을 낮춰 조정
패치패널: 판단 유보 4건	→	**근거 페이지를 이의 시점에 재확인**	숨은 칸의 가격과 화면 가격이 엇갈리는 점을 설명

결과 이의 41건이 모두 접수됐고, 인정액은 잠정에서 최종 확정액으로 올랐습니다(결과 카드 참고). 건별 이의 결과는 비공개라 개별 효과는 분리하지 못했습니다(한계 참고). 운영 기록

한계

해석 주의 **판정은 시중가 비교 추정**

심사에서 근거 부족일 수 있어 접수 금액보다 확정액이 낮았습니다(결과 카드 참고, 최초 제출 시 금액은 13.7억 원).

해석 주의 **이의 효과를 분리하지 못함**

건별 이의 결과가 공개되지 않아 인정액 상승에서 이의 효과와 잠정 때 비공개였던 65건의 영향을 나눌 수 없습니다.

배운 점 **근거 종류의 사전 점검이 늦었음**

먼저 등록한 사람이 갖는 대회라 139건 중 106건을 첫 이틀에 냈지만, 데스크톱·랙 반려 사유(판매 페이지 아님, 52건 전부)는 마감 뒤(10.30)에야 알았고 근거 종류의 인정 여부를 첫 제출 전에 점검했어야 했습니다.

해석 주의 **제출 수치의 기준**

제출 117건(철회 22건 제외, 운영진 반려 39건 포함)과 접수 금액은 내 제출 기록 기준, 확정액·순위는 공식 결과 기준이며 테스트는 합성 데이터입니다.

OIBC 2026

개인 진행 중

태양광 발전량 예측과 VPP 배정을 규칙 위반 없이 비교하는 파이프라인

2026 POSTECH OIBC 빅데이터 경진대회에서 태양광 발전소를 두 개의 가상발전소(VPP, 발전소 묶음)로 나눠 하루 전 시간별 발전량을 예측합니다. 점수보다 규칙 준수를 먼저 두어, 예측 마감 이후 정보 차단과 사전에 정한 채택 규칙을 코드로 고정했습니다.

기간 2026.10 ~ 진행 중

역할 대회 개인 참가, 데이터 정제부터 예측·배정·제출 검증까지 단독 설계·구현

규모 src 약 9,300줄 · 테스트 969개

기술 Python LightGBM CatBoost scikit-learn pandas NumPy PyArrow(Parquet) SciPy Pydantic pytest uv

저장소 github.com/KTHYEONG/oibc-2026

배정 대상

253곳 → 2개 VPP

한 번씩만 배정, 그룹별 용량 20,000kW 이상, 제약은 코드와 테스트로 검증

사례

CASE 01

예측 마감 이후 정보 차단

원천 예보	발행 시각 확인	마감 이후면 중단	파생 테이블	특성 패널
발행 시각 포함	대상 운영일 마감과 비교	오류로 멈춤	마감 이전 정보만	모델 입력

P 문제 전날 17:00 이후의 정보를 쓰면 대회 규칙 위반인데, 시계열 데이터는 실수로 미래 정보가 섞이기 쉽습니다.

전날 17:00
예측 마감, 이후 발행된 예보를 쓰면 오류로 중단

KST 오른쪽 닫힘
모든 시각 통일, 01:00은 00~01시

테스트 14개
게이트 모듈 단위 테스트

A 분석
- 모델 쪽에서 조심하는 방식은 특성이 늘수록 빈틈이 생겨 제외하고, 데이터를 파생하는 단계에서 막는 방식을 채택
- 시각 표기가 섞이면 한 시간 어긋나 미래 정보가 들어갈 수 있어 시각 규칙부터 통일

A 실행
- 예보 발행 시각이 대상 운영일의 마감보다 늦으면 기본값으로 대체하지 않고 오류로 중단
- 마감 이후 예보를 망가뜨려도 이전 날의 특성이 바뀌지 않는지 테스트

R 결과 마감 게이트·시간축·정산 규칙을 단위 테스트로 고정했습니다.

한계

해석 주의 **제출 중이라 결과 미정**
제출 기간(2026-11-02 ~ 11-13) 중이라 최종 순위와 검증 개선 폭은 정해지지 않았습니다.

해석 주의 **완전한 검증 데이터가 아님**
검증용 마지막 12개월은 이미 모델 비교에 쓰였습니다.

미검증 **지리 반클러스터링의 효과**
벌점을 줄이는지는 검증 결과로 확인해야 하는 가정입니다.

해석 주의 **리더보드 의존 제출은 무효 처리**
리더보드를 본 뒤 정한 배율 제출은 운영팀 답변 후 스스로 무효로 보고 유효 최고점을 따로 관리합니다.

기술 · 기타

사용한 기술

Python · pytest · PyArrow(Parquet) · LightGBM · pandas · pydantic · scikit-learn · uv · asyncio/WebSocket · Polars · SQLite · zstandard · Docker Compose · aiohttp · systemd · RapidFuzz · PyTorch · Kanana 1.5 2.1B

AI 활용 방식

AI 코딩 도구를 코드 작성과 처음 접하는 분야 학습에 활용했습니다. 설계와 검증은 직접 맡고, 구현을 AI와 나눴습니다.

설계	구현	검증
직접	**AI 도구**	**직접**
문제 정의와 비교 기준, 구조를 먼저 정합니다.	정한 설계대로 코드를 작성하고, 저는 변경 내용을 검토합니다.	테스트와 정적 검사를 통과시키고, 결과 수치는 직접 확인한 것만 씁니다.

수치 기준 표기

- **백테스트** — 과거 데이터 시뮬레이션
- **재현 시뮬레이션** — 체결·증거금 규칙을 적용한 원장 리플레이
- **평가셋 측정** — 정해진 평가 데이터로 잰 값
- **팀 측정** — 팀 전체 측정값(제 기여분만의 값이 아님)
- **운영 기록** — 실제로 돌린 기록

그 밖의 프로젝트

auto-mobility 실내 공간을 3D 모델로 복원하고 센서 데이터로 검증하는 온라인 현장실습 팀 프로젝트(3명). 저는 Visual SLAM 비교와 평가를 주로 맡았습니다.

K-Stock Engine 국내주식 다중 팩터 전략을 연구하고 가상 장부로 기록합니다. 아직 불완전한 단계라 성과는 싣지 않았습니다.

연락

xogud3624@gmail.com · github.com/KTHYEONG · kthyeong.github.io